

Das Simpson-Paradoxon an der UC Berkeley

Zulassungen 1973:

Funktionen in Python, Visualisierung und stochastische Unabhängigkeit

Vortrag 4 · Statistik · Wirtschaftsinformatik · Kleinklasse HS 2026

Leorat Krasniqi · Teoman-Doganay Lam · Filip Lazic

Ausgangslage: Diskriminierung in Berkeley?

- 4 526 Bewerbungen für ein Graduate-Studium an den 6 grössten Fachbereichen (A bis F)
- Tabelle 4: Zulassungsquote je Fachbereich und Geschlecht sowie Verteilung der Bewerbungen
- **Aufgabe (a): Funktionen in Python (McKinney, 2018, Abschnitt 3.2)**
- **Aufgabe (b): Die Ungerechtigkeit auf einen Blick darstellen**
- **Aufgabe (c): Verteilungen vergleichen, stochastische Unabhängigkeit prüfen**

(a) Funktionen in Python: Grundlagen

- `def` deklariert, `return` gibt zurück (ohne `return: None`)
- Positions- und Keyword-Argumente mit Standardwert
- Lokaler Namensraum; global vermeiden
- Mehrere Rückgabewerte = ein Tupel, alternativ Dictionary

```
def kreuztabelle(daten, fachbereich=None):
    if fachbereich is not None:
        daten = daten[daten["Fachbereich"] == fachbereich]
    return daten.pivot_table(index="Geschlecht",
                              columns="Entscheid",
                              values="Anzahl", aggfunc="sum")

def kennzahlen(zugelassen, abgelehnt, total):
    bewerbungen = zugelassen + abgelehnt
    return zugelassen / bewerbungen, bewerbungen / total

quote, anteil = kennzahlen(89, 19, 1835) # Tupel entpacken
```

(a) Funktionen als Objekte, Lambda, yield

```
# Funktionen in einer Liste -> nacheinander anwenden
bereinigungs_schritte = [str.strip, entferne_prozentzeichen, in_anteil]
tab4 = bereinige(["82.4%", "68.0%", ...], bereinigungs_schritte)

# Lambda-Funktion und Currying
prozent = lambda x: f"{x:.1%}"
quote_frauen = partial(bedingte_quote, geschlecht="Frauen")


# Generator: liefert Ergebnisse erst auf Anfrage
def ergebnisse_je_fachbereich(daten, fachbereiche):
    for fb in fachbereiche:
        yield fb, pruefe_unabhaengigkeit(kreuztabelle(daten, fachbereich=fb))

# Ausnahmebehandlung: nur den erwarteten Fehler abfangen
def in_anteil(wert):
    try:
        return float(wert) / 100
    except ValueError:
        raise ValueError(f"Ungültiger Tabellenwert: {wert!r}")
```

Vorüberlegungen zur Umsetzung


- Tabelle 4 enthält nur Prozente, deshalb Anzahlen aus dem Originaldatensatz; der Code prüft sie gegen Tabelle 4: 0 Abweichungen
- Plausibilitätskontrolle: $P(Z | G) = \sum P(F_i | G) \cdot P(Z | F_i, G)$ ergibt die Zeile «Total»
- Langes DataFrame (Fachbereich × Geschlecht × Entscheid), daraus jede Kreuztabelle mit `pivot_table`
- Wiederholte Schritte als Funktionen: `gesamt` und für jeden der 6 Fachbereiche
- Diagramme wie im Kurs: Säulen-, gruppiertes Säulen- und Streudiagramm
- **pandas: Tabellen · numpy: Rechnen · matplotlib: Diagramme · re/functools: Standardbibliothek**

(b) Die scheinbare Ungerechtigkeit





- Männer: 44.5 %
- Frauen: 30.4 %
- Differenz: 14.2 Prozentpunkte
- Bei Männerquote: 817 statt 557 Frauen zugelassen
- **Also Diskriminierung?**

(c) Je Fachbereich: kein Nachteil für Frauen



- In 4 von 6 Fachbereichen haben Frauen die höhere Quote
- FB A: +20.3 Prozentpunkte
- FB C und E: –2.9 bzw. –3.8 Prozentpunkte


(c) Frauen wählten selektivere Fachbereiche



Männer: 51.5 % bewerben sich in A oder B (Zulassungsquote $\approx 64\%$) · Frauen: nur 7.2 %

Je höher der Frauenanteil, desto tiefer die Zulassungsquote des Fachbereichs ($r = -0.79$)

(c) Die Erklärung: totale Wahrscheinlichkeit



$$P(Z | G) = \sum P(F_i | G) \cdot P(Z | F_i, G)$$

Gesamtquote = gewichteter
Mittelwert der Fachbereichsquoten

Gleiche Gewichte für beide
Geschlechter:

Frauen 43.0 % · Männer 38.7 %

`gesamtquote(quote_g[g],
gewichte_alle)`

(c) Stochastische Unabhängigkeit

Z, W unabhängig $\Leftrightarrow P(Z \cap W) = P(Z) \cdot P(W) \Leftrightarrow P(Z | W) = P(Z)$

	P(Z W)	P(Z M)	Differenz	P(Z∩W)	P(Z)·P(W)	Beurteilung
Gesamt	30.4 %	44.5 %	−14.2 PP	0.1231	0.1572	abhängig
FB A	82.4 %	62.1 %	+20.3 PP	0.0954	0.0746	abhängig, zugunsten Frauen
FB B	68.0 %	63.0 %	+5.0 PP	0.0291	0.0270	annähernd unabhängig (nur 25 Frauen)
FB C	34.1 %	36.9 %	−2.9 PP	0.2200	0.2266	annähernd unabhängig
FB D	34.9 %	33.1 %	+1.8 PP	0.1654	0.1608	annähernd unabhängig
FB E	23.9 %	27.7 %	−3.8 PP	0.1610	0.1694	annähernd unabhängig
FB F	7.0 %	5.9 %	+1.1 PP	0.0336	0.0308	annähernd unabhängig

Insgesamt abhängig, innerhalb der Fachbereiche (bis auf A) annähernd unabhängig

Fazit

- Aggregiert: Zulassung und Geschlecht sind stochastisch abhängig (30.4 % vs. 44.5 %)
- Je Fachbereich: kein Nachteil für Frauen; gegeben den Fachbereich annähernd unabhängig
- Ursache: Frauen bewarben sich häufiger in stark umkämpften Fachbereichen
- **Simpson-Paradoxon: Die Drittvariable Fachbereich kehrt den Zusammenhang um**
- Grenzen: Beobachtungsdaten eines Jahres; Gründe für die Fachbereichswahl bleiben offen
- Python: Dieselben Funktionen für Gesamtanalyse, 6 Fachbereiche und Standardisierung

Literaturverzeichnis · Fragen?

Bickel, P. J., Hammel, E. A., & O'Connell, J. W. (1975). Sex bias in graduate admissions: Data from Berkeley. *Science*, 187(4175), 398–404. <https://doi.org/10.1126/science.187.4175.398>

McKinney, W. (2018). *Datenanalyse mit Python* (2., korrigierte Aufl.). O'Reilly.

R Core Team. (o. J.). *UCBAdmissions: Student admissions at UC Berkeley* [Datensatz]. R-Paket datasets. <https://github.com/wch/r-source/blob/trunk/src/library/datasets/data/UCBAdmissions.R>

Schnauss, M. (o. J.-a). *Statistik (w.BA.XX.2Stat-WIN.XX), Teil 1: Tabellen und Diagramme* [Vorlesungsfolien]. ZHAW School of Management and Law.

Schnauss, M. (o. J.-b). *Statistik (w.BA.XX.2Stat-WIN.XX), Teil 3: Wahrscheinlichkeitsrechnung* [Vorlesungsfolien]. ZHAW School of Management and Law.

Simpson, E. H. (1951). The interpretation of interaction in contingency tables. *Journal of the Royal Statistical Society: Series B (Methodological)*, 13(2), 238–241. <https://doi.org/10.1111/j.2517-6161.1951.tb00088.x>

ZHAW School of Management and Law. (2026). *Aufgabe 4 (Vortrag-4: Python)* [Aufgabenblatt].

Code und Ausarbeitung: Vortrag4_Berkeley_Analyse.ipynb, Vortrag4_Ausarbeitung.docx