

Sprechtext: Das Simpson-Paradoxon an der UC Berkeley

Leorat Krasniqi · Teoman-Doganay Lam · Filip Lazic — passend zu Vortrag4_Praesentation.pptx (18 Folien)

So benutzt ihr diesen Text

- Der Text ist zum Üben gedacht, nicht zum Ablesen. Sprecht frei und nutzt die fett gedruckten Merksätze als Stichworte.
- Die Zeitangaben ergeben rund 15 Minuten, wie in den Regeln verlangt (3 × 5 Minuten). Das Aufgabenblatt nennt 20 Minuten: Falls die gelten, nehmt die grau markierten «Ergänzungen für 20 Minuten» dazu und plant mehr Zeit für Fragen ein.
- Derselbe Text steht in der PowerPoint-Datei in den Notizen jeder Folie (Ansicht → Notizen oder Referentenansicht).
- Probt einmal mit Stoppuhr. Wenn es zu lang wird, kürzt zuerst bei Folie 6 und Folie 8.

Aufteilung

Person	Folien	Inhalt	Zeit
Leorat Krasniqi	1–6	Einstieg, Ablauf, Aufgabe (a) Funktionen in Python	ca. 5 Min.
Teoman-Doganay Lam	7–12	Vorüberlegungen, Aufgabe (b), Vergleich je Fachbereich, Bewerbungen	ca. 5 Min.
Filip Lazic	13–18	Totale Wahrscheinlichkeit, Unabhängigkeit, Kernaussage, Fazit	ca. 5 Min.

Kriterien-Check (Aufgabenblatt)

Anforderung	Wo im Vortrag
Vortrag mit theoretischen Hintergründen	Folien 5, 6 (Funktionen), 13 (totale Wahrscheinlichkeit), 14 (bedingte Wahrscheinlichkeit, Unabhängigkeit), 16 (Simpson-Paradoxon)
(a) Funktionen in Python nach McKinney, Abschnitt 3.2	Folien 4–6, alle Konzepte mit Seitenangabe und eigenem Code
(b) Verhältnisse darstellen, Umsetzung in Python	Folie 9: Balkendiagramm, –14.2 Prozentpunkte, 817 statt 557
(c) Verteilungen vergleichen und interpretieren	Folien 11–13 und 16–17
(c) Stochastische Unabhängigkeit	Folien 14–15: insgesamt abhängig, je Fachbereich annähernd unabhängig
Python-Code erläutern und kommentieren	Folien 5–6 zeigen Code; im Sprechtext bei 8, 9, 11, 13, 14 und 15 mit Funktionsnamen erklärt
Verwendung der Libraries begründen	Folie 8 (pandas, numpy, matplotlib, re/functools)
Schwerpunkt Vorüberlegungen zur Umsetzung	Folie 8: fünf Schritte, Anzahlen aus Originaldaten, Prüfung mit 0 Abweichungen
Dauer 15 Minuten (Regeln) bzw. 20 Minuten (Aufgabenblatt)	Kerntext ca. 15 Minuten; mit den markierten Ergänzungen und Fragen ca. 20 Minuten

Begriffe in einfachen Worten

Diese Begriffe sollte jede und jeder von euch in einem Satz erklären können, auch wenn sie in eurem Teil nicht vorkommen.

Begriff	Einfach erklärt
Funktion	Ein Rezept mit Namen: Zutaten (Argumente) rein, immer dieselben Schritte, Ergebnis (return) raus.
Argument mit Standardwert	Eine Voreinstellung: Gibt man nichts an, nimmt Python den vorgegebenen Wert.
Tupel / Dictionary	Mehrere Ergebnisse in einem Paket. Beim Dictionary hat jedes Ergebnis einen Namen.
Lambda	Eine Mini-Funktion ohne Namen, nur eine Zeile lang.
partial (Currying)	Ein Argument fest einbauen, so entsteht eine speziellere Funktion (z. B. <code>quote_frauen</code>).
Generator (yield)	Liefert Ergebnisse eines nach dem anderen, wie ein Kellner Gang für Gang.
Library	Ein fertiger Werkzeugkasten, z. B. pandas für Tabellen und matplotlib für Diagramme.

Zulassungsquote	Anteil der Bewerbungen, die angenommen wurden, z. B. 557 von 1 835 Frauen = 30.4 %.
Prozentpunkte	Differenz zweier Prozentwerte: 44.52 % – 30.35 % $\approx$ 14.2 Prozentpunkte. Nicht «14.2 Prozent» sagen!
Bedingte Wahrscheinlichkeit $P(Z W)$	Wahrscheinlichkeit für «zugelassen», wenn man nur die Bewerbungen von Frauen betrachtet.
$P(Z \cap W)$	Anteil aller Bewerbungen, die von einer Frau stammen UND zugelassen wurden.
Stochastisch unabhängig	Das eine Merkmal ändert nichts am anderen: Das Geschlecht spielt für die Zulassung keine Rolle. Prüfung: $P(Z \cap W) = P(Z) \cdot P(W)$.
Gewichteter Mittelwert	Wie der Notenschnitt mit ECTS: Was mehr Gewicht hat, zählt mehr.
Totale Wahrscheinlichkeit	Gesamtquote = Summe über alle Fachbereiche von Anteil $\times$ Quote dort («alle Wege im Baumdiagramm»).
Korrelation	Mass von -1 bis $+1$ für einen Zusammenhang. -0.79 : je mehr Frauen, desto tiefer die Quote, und zwar deutlich.
Simpson-Paradoxon	Jede Gruppe einzeln zeigt etwas anderes als alle Gruppen zusammen, weil eine Drittvariable (hier der Fachbereich) mitspielt.

ALLE

Folie 1 · Titel

0:00–0:30 · Alle

Guten Tag zusammen. Wir sind Leorat Krasniqi, Teoman-Doganay Lam und Filip Lazic.

Unser Thema ist ein Klassiker der Statistik: die Zulassungen an der University of California in Berkeley im Jahr 1973. An diesem Beispiel zeigen wir, wie man mit Python Daten auswertet und darstellt, und warum ein einzelner Durchschnittswert manchmal genau das Falsche erzählt.

Merksatz: Wir zeigen Python, Visualisierung und stochastische Unabhängigkeit an einem echten Datensatz.

LEORAT KRASNIQI

Folie 2 · Ausgangslage

0:30–1:20 · Leorat Krasniqi

1973 gingen an den sechs grössten Fachbereichen der UC Berkeley 4 526 Bewerbungen für ein Graduate-Studium ein.

Von den Männern wurden 44.5 Prozent zugelassen, also 1 198 von 2 691. Von den Frauen waren es nur 30.4 Prozent, 557 von 1 835.

Die naheliegende Frage steht unten auf der Folie: Werden Frauen im Zulassungsverfahren benachteiligt? Genau diese Frage haben Bickel und Kollegen 1975 in der Zeitschrift Science untersucht. Wir gehen ihr mit Python nach.

Merksatz: 44.5 % gegenüber 30.4 %: Auf den ersten Blick sieht das nach Benachteiligung aus.

Folie 3 · Ablauf

1:20–1:50 · Leorat Krasniqi

Unsere Aufgabe hat drei Teile. In Teil a erkläre ich Funktionen in Python nach McKinney, Abschnitt 3.2, und zeige, wo wir sie im eigenen Code einsetzen.

In Teil b zeigt Teoman unsere Vorüberlegungen und ein Diagramm, aus dem man die scheinbare Ungerechtigkeit sofort sieht.

In Teil c schauen Teoman und Filip genauer hin: Sie vergleichen die Verteilungen und prüfen die stochastische Unabhängigkeit.

Merksatz: a = Funktionen, b = Darstellung, c = Vergleich und Unabhängigkeit.

Folie 4 · Kapiteltrenner a

1:50–2:00 · Leorat Krasniqi

Wir beginnen mit Teil a: Funktionen in Python.

Folie 5 · Funktionen: die Grundlagen

2:00–3:40 · Leorat Krasniqi

Eine Funktion kann man sich wie ein Rezept vorstellen: Man gibt Zutaten hinein, sie arbeitet immer dieselben Schritte ab und gibt ein Ergebnis zurück. Laut McKinney sind Funktionen deshalb die wichtigste Methode, um Code zu ordnen und wiederzuverwenden.

Links sehen Sie die vier Grundlagen. Erstens: Mit `def` gibt man dem Rezept einen Namen, mit `return` gibt es das Ergebnis heraus.

Zweitens die Argumente, also die Zutaten. Man kann sie der Reihe nach übergeben oder mit ihrem Namen. Ein Argument mit Namen kann eine Voreinstellung haben: Gibt man nichts an, nimmt Python diesen Standardwert.

Rechts sehen Sie das in unserem Code. Die Funktion `kreuztabelle` zählt, wie viele Frauen und Männer zugelassen und abgelehnt wurden. Das Argument `fachbereich` ist standardmässig leer. Ruft man sie ohne Angabe auf, zählt sie über alle Bewerbungen. Schreibt man `fachbereich` gleich `A`, zählt sie nur in Fachbereich A. Eine einzige Funktion reicht so für das Gesamtbild und alle sechs Fachbereiche.

Drittens: Was in einer Funktion passiert, bleibt in der Funktion. Ihre Variablen verschwinden nach dem Aufruf wieder. Deshalb geben wir jeder Funktion die Daten ausdrücklich mit, statt irgendwo global darauf zuzugreifen.

Viertens: Eine Funktion kann mehrere Ergebnisse in einem Paket zurückgeben, einem sogenannten Tupel. Unsere Funktion `kennzahlen` liefert so `Quote` und `Anteil` auf einmal.

Merksatz: `def`, `return`, Keyword-Argument mit Standardwert: Eine Funktion ersetzt sieben Kopien desselben Codes.

Ergänzung für 20 Minuten: Statt eines Tupels kann man auch ein Dictionary zurückgeben. Das machen wir in `pruefe_unabhaengigkeit`, weil sie neun Kennzahlen liefert, die man so über ihren Namen ansprechen kann (McKinney, S. 74).

Folie 6 · Fünf weitere Konzepte

3:40–5:10 · Leorat Krasniqi

Links steht McKinneys Faustregel: Code, den man mehr als einmal braucht, gehört in eine Funktion. Rechts sehen Sie fünf weitere Konzepte aus Abschnitt 3.2, jeweils mit einer Zeile aus unserem Code.

Erstens kann man Funktionen wie normale Werte behandeln, zum Beispiel in eine Liste packen. Das ist wie eine Checkliste mit Arbeitsschritten: Leerzeichen entfernen, Prozentzeichen entfernen, in eine Zahl umwandeln. Jeder Wert aus Tabelle 4 läuft einmal durch diese Liste.

Zweitens Lambda-Funktionen: kleine Funktionen ohne Namen, die nur eine Zeile lang sind. Wir brauchen sie zum Beispiel, damit an den Achsen «40 %» statt «0.4» steht.

Drittens partial, bei McKinney Currying genannt: Man legt ein Argument fest und erhält eine neue, speziellere Funktion. Aus der allgemeinen Funktion `bedingte_quote` wird so `quote_frauen`, die immer nur die Zulassungsquote der Frauen berechnet.

Viertens ein Generator mit `yield`: Er arbeitet wie ein Kellner, der Gang für Gang bringt statt alles auf einmal. Bei uns liefert er die Ergebnisse Fachbereich für Fachbereich.

Und fünftens die Fehlerbehandlung: Steht in der Tabelle aus Versehen etwas, das keine Zahl ist, bekommen wir eine klare Fehlermeldung, statt unbemerkt mit einem falschen Wert weiterzurechnen.

Damit übergebe ich an Teoman.

Merksatz: Alle Konzepte aus Abschnitt 3.2 kommen in unserem eigenen Code vor, nicht nur in Beispielen.

TEOMAN-DOGANAY LAM

Folie 7 · Kapiteltrenner b

5:10–5:20 · Teoman-Doganay Lam

Danke, Leorat. Bevor wir zu Teil b kommen, zeige ich, wie wir die Umsetzung geplant haben.

Folie 8 · Vorüberlegungen: fünf Schritte

5:20–6:50 · Teoman-Doganay Lam

Die erste Frage war: Was liegt eigentlich vor? Tabelle 4 enthält nur Prozentwerte, also Zulassungsquoten und Anteile. Daraus ergeben sich unsere fünf Schritte.

Schritt 1 und 2: Wir erfassen Tabelle 4 wortgetreu als Text, zum Beispiel «82.4%», und machen mit der Liste von Funktionen, die Leorat gezeigt hat, Zahlen daraus. So bleibt die Datenerfassung nachvollziehbar.

Schritt 3 ist der wichtigste. Prozente sagen nur «wie viel von», aber nicht «wie viele». Für Teil c brauchen wir aber Anzahlen, zum Beispiel wie viele Frauen sich insgesamt beworben haben. Wir übernehmen sie deshalb aus dem Originaldatensatz, der in R als UCBAmissions frei verfügbar ist. Zur Sicherheit prüft unser Code, dass diese Anzahlen genau die 24 Prozentwerte aus Tabelle 4 ergeben. Ergebnis: keine einzige Abweichung.

Schritt 4: Wir speichern die Daten als eine lange Liste, eine Zeile pro Fachbereich, Geschlecht und Entscheid. Daraus kann die Funktion kreuztabelle jede Tabelle bauen, die wir brauchen.

Schritt 5: Als Diagrammtypen verwenden wir die aus dem Kurs, also Säulen- und Balkendiagramme für Kreuztabellen und im Notebook zusätzlich ein Streudiagramm.

Unten stehen die Libraries, also fertige Werkzeugkästen, und warum wir sie gewählt haben. pandas ist wie Excel in Python: Tabellen filtern und zusammenfassen geht in einer Zeile. numpy rechnet mit ganzen Spalten auf einmal. matplotlib zeichnet die Diagramme, und wir können Farben und Beschriftungen genau festlegen. re und functools sind bereits in Python eingebaut. Alle diese Libraries sind in Anaconda enthalten, das wir im Kurs verwenden.

Merksatz: Erst prüfen, dann rechnen: Die Anzahlen reproduzieren Tabelle 4 ohne eine einzige Abweichung.

Ergänzung für 20 Minuten: Als Plausibilitätskontrolle rechnet der Code auch die Zeile «Total» aus den Fachbereichswerten nach. Das ergibt 30.4 und 44.6 Prozent, die Differenz von 0.1 zur Tabelle entsteht nur durch Rundung.

Folie 9 · Die scheinbare Ungerechtigkeit

6:50–8:00 · Teoman-Doganay Lam

Teil b verlangt eine Darstellung, aus der man die Ungerechtigkeit schnell erkennt. Dafür reicht ein einziger Vergleich: die Zulassungsquote aller Frauen gegen die aller Männer.

Wir haben bewusst ein einfaches Balkendiagramm gewählt, mit Nullachse, damit die Längen ehrlich vergleichbar sind, und mit den Werten direkt an den Balken. Die Farben bleiben in der ganzen Präsentation gleich: Orange für Frauen, Blau für Männer.

Das Ergebnis: 30.4 gegen 44.5 Prozent, also 14.2 Prozentpunkte weniger für Frauen. Exakt gerechnet sind es 44.52 minus 30.35. Die Quote der Männer ist damit fast 1.5-mal so hoch. Anders gesagt: Mit der Quote der Männer wären 817 statt 557 Frauen zugelassen worden.

Im Code übernimmt matplotlib das Zeichnen. Die Werte schreibt unsere Funktion `saeulen_beschriften` an die Säulen. Ihr übergeben wir die Formatierung als Funktion, wieder ein Konzept aus Teil a.

Also Diskriminierung? Genau diesen Schluss prüfen wir jetzt.

Merksatz: Aggregiert: 14.2 Prozentpunkte weniger für Frauen. Die Frage ist, ob dieser Schluss hält.

Folie 10 · Kapiteltrenner c

8:00–8:10 · Teoman-Doganay Lam

Teil c: Wir schauen genauer hin.

Folie 11 · Je Fachbereich

8:10–9:10 · Teoman-Doganay Lam

Über die Zulassung entscheidet nicht die Universität als Ganzes, sondern jeder Fachbereich für sich. Deshalb vergleichen wir die Quoten innerhalb der Fachbereiche. Im Code ist das dieselbe Funktion, nur mit dem Argument `fachbereich`.

Und das Bild dreht sich: In vier von sechs Fachbereichen haben Frauen die höhere Quote. In Fachbereich A sind es sogar gut 20 Prozentpunkte mehr, 82.4 gegen 62.1 Prozent.

Nur in C und E liegen die Männer vorne, mit knapp 3 und knapp 4 Prozentpunkten. Unter jedem Fachbereich steht die Differenz. Wir haben sie aus den ungerundeten Anzahlen berechnet, deshalb steht bei C minus 2.9.

Wie passt das zur viel tieferen Gesamtquote der Frauen?

Merksatz: Innerhalb der Fachbereiche gibt es keinen systematischen Nachteil für Frauen.

Folie 12 · Wo sich Frauen und Männer bewarben

9:10–10:20 · Teoman-Doganay Lam

Die Antwort liegt darin, wo sich Frauen und Männer beworben haben. Dunkel sind die Fachbereiche A und B. Dort werden knapp zwei Drittel aller Bewerbungen angenommen. Grau sind C bis F mit Quoten zwischen 6 und 35 Prozent.

Von den Männern hat sich gut die Hälfte in A oder B beworben, genau 51.5 Prozent. Von den Frauen waren es nur 7.2 Prozent. 92.8 Prozent der Frauen haben sich also in den schwierigen Fachbereichen beworben.

Rechts sieht man das für alle sechs Fachbereiche: Je höher der Frauenanteil, desto tiefer die Zulassungsquote. Die Korrelation beträgt minus 0.79. Minus heisst «je mehr, desto weniger», und 0.79 ist nahe bei 1, also ein starker Zusammenhang. Zwei Beispiele: In A sind 11.6 Prozent der Bewerbungen von Frauen, die Quote liegt bei 64.4 Prozent. In E sind es 67.3 Prozent Frauen, und die Quote liegt nur bei 25.2 Prozent.

Damit übergebe ich an Filip.

Merksatz: Frauen bewarben sich vor allem dort, wo es schwer ist.

Folie 13 · Die Gesamtquote ist ein gewichteter Mittelwert

10:20–11:40 · Filip Lazic

Danke, Teoman. Warum führt das zu einer tieferen Gesamtquote? Das erklärt der Satz der totalen Wahrscheinlichkeit. Im Folienskript heisst es: alle Wege im Baumdiagramm addieren.

Die Formel oben sagt: Man nimmt für jeden Fachbereich den Anteil der Bewerbungen mal die Quote dort und zählt alles zusammen. Das kennen Sie vom Notenschnitt: Ein Modul mit vielen ECTS zählt mehr als eines mit wenigen. Hier zählt ein Fachbereich mehr, je mehr Bewerbungen dort eingingen.

Bei den Frauen zählen also genau die Fachbereiche mit tiefen Quoten am meisten. Das drückt ihren Schnitt nach unten. Deshalb haben wir gerechnet, als hätten sich Frauen und Männer genau gleich auf die Fachbereiche verteilt, nämlich so wie alle 4 526 Bewerbungen zusammen.

Das Ergebnis sehen Sie rechts: Frauen 43.0 Prozent, Männer 38.7 Prozent. Bei gleicher Fachbereichswahl liegen also die Frauen vorne.

Im Code ist das eine einzige Zeile: Die Funktion `gesamtquote` multipliziert Quoten und Anteile und summiert. Für die Standardisierung rufen wir sie nur mit anderen Gewichten auf.

Merksatz: Die Gesamtquote ist ein gewichteter Mittelwert. Die Gewichte, also die Fachbereichswahl, erzeugen den Unterschied.

Ergänzung für 20 Minuten: Die gemeinsamen Gewichte sind die Anteile aller Bewerbungen je Fachbereich: A 20.6 %, B 12.9 %, C 20.3 %, D 17.5 %, E 12.9 % und F 15.8 %.

Folie 14 · Insgesamt abhängig

11:40–12:50 · Filip Lazic

Nun zur stochastischen Unabhängigkeit, wie im Folienskript Teil 3. Z steht für «zugelassen», W für «Bewerbung einer Frau». Die Zulassungsquoten von vorhin sind bedingte Wahrscheinlichkeiten, zum Beispiel P von Z gegeben W.

Unabhängig heisst ganz einfach: Das Geschlecht spielt für die Zulassung keine Rolle. Formal gilt dann: P von Z geschnitten W gleich P von Z mal P von W. Wir prüfen das genau wie im Beispiel mit Navi und Klimaanlage.

In Worten: 38.8 Prozent aller Bewerbungen wurden zugelassen, 40.5 Prozent stammen von Frauen. Spielt das Geschlecht keine Rolle, müssten 38.8 Prozent von diesen 40.5 Prozent zugelassene Frauen sein, das sind 15.7 Prozent aller Bewerbungen. Tatsächlich sind es aber nur 12.3 Prozent, rund 22 Prozent weniger als erwartet.

Über alle Fachbereiche zusammen sind Zulassung und Geschlecht damit stochastisch abhängig.

Im Code berechnet das die Funktion `pruefe_unabhaengigkeit`. Sie gibt alle Kennzahlen als Dictionary zurück, das ist wie ein Nachschlagewerk: Jede Zahl hat einen Namen, unter dem man sie findet.

Merksatz: Gesamt: 0.123 statt 0.157, also abhängig.

Ergänzung für 20 Minuten: Zur Kontrolle ergibt $P(Z \cap W)$ geteilt durch $P(W) = 0.1231 / 0.4054 = 0.304$, also genau die Zulassungsquote der Frauen.

Folie 15 · Je Fachbereich annähernd unabhängig

12:50–14:00 · Filip Lazic

Dieselbe Prüfung haben wir für jeden Fachbereich gemacht. Im Code liefert der Generator die Ergebnisse Fachbereich für Fachbereich.

Links sehen Sie die Differenz der Quoten. In B bis F beträgt sie höchstens 5 Prozentpunkte, und die Richtung wechselt: In B, D und F liegen die Frauen vorne, in C und E die Männer. Bei B beruht das zudem auf nur 25 Bewerbungen von Frauen.

Rechts liegen der beobachtete und der erwartete Wert jeweils nahe beieinander. Innerhalb der Fachbereiche spielt das Geschlecht also kaum eine Rolle, Zulassung und Geschlecht sind annähernd unabhängig.

Die einzige deutliche Abweichung ist Fachbereich A, und die geht zugunsten der Frauen.

Wichtig: Unsere Beurteilung ist beschreibend. Ob kleine Abweichungen zufällig sind, würde ein Hypothesentest klären. Den behandeln wir im Kurs erst später.

Merksatz: Insgesamt abhängig, innerhalb der Fachbereiche annähernd unabhängig.

Folie 16 · Kernaussage

14:00–14:30 · Filip Lazic

Damit sind wir bei der Kernaussage: Der Fachbereich erklärt den Unterschied.

Frauen bewarben sich häufiger in stark umkämpften Fachbereichen. Schaut man jeden Fachbereich einzeln an, haben Frauen keinen Nachteil. Wirft man alle zusammen, sieht es plötzlich nach einem Nachteil aus. Dieses Phänomen heisst nach Edward Simpson das Simpson-Paradoxon. Die Berkeley-Daten werden häufig verwendet, um es zu veranschaulichen.

Merksatz: Eine Drittvariable, hier der Fachbereich, kann einen Zusammenhang beim Zusammenfassen umkehren.

Folie 17 · Fazit

14:30–15:10 · Filip Lazic

Drei Punkte zum Mitnehmen. Erstens: Über alle Fachbereiche zusammen sind Zulassung und Geschlecht abhängig, 30.4 gegen 44.5 Prozent.

Zweitens: In den Fachbereichen zeigt sich kein systematischer Nachteil für Frauen, in Fachbereich A liegen sie sogar deutlich vorne.

Drittens: Die Ursache ist die Wahl des Fachbereichs. Bei gleicher Wahl läge die Quote der Frauen bei 43.0, die der Männer bei 38.7 Prozent.

Unsere Analyse hat auch Grenzen. Es sind Beobachtungsdaten eines einzigen Jahres. Warum Frauen die selektiveren Fachbereiche wählten und wie qualifiziert die Bewerbenden waren, sagen die Daten nicht.

Und programmtechnisch: Dank Funktionen konnten wir denselben Code für die Gesamtanalyse, alle sechs Fachbereiche und die Standardisierung verwenden.

Merksatz: Abhängig insgesamt, kein systematischer Nachteil je Fachbereich, Ursache ist die Fachbereichswahl.

Folie 18 · Fragen

15:10–15:20 · Filip Lazic

Vielen Dank für Ihre Aufmerksamkeit. Rechts finden Sie unsere Quellen. Wir freuen uns auf Ihre Fragen.

Vorbereitung auf die Fragerunde

Mögliche Fragen der Dozentin bzw. des Dozenten oder der Klasse, mit kurzen Antworten. Wer antwortet, ist in Klammern vorgeschlagen.

Warum nehmt ihr Anzahlen aus R und nicht nur Tabelle 4? (Teoman-Doganay)

Tabelle 4 enthält nur Prozente. Für $P(W)$ und $P(Z \cap W)$ braucht es das Verhältnis Frauen zu Männern. Aus gerundeten Prozenten zurückgerechnet ergäbe sich zum Beispiel 26 statt 25 Frauen in B. Die Originalanzahlen reproduzieren alle 24 Werte der Tabelle ohne Abweichung.

Warum 14.2 und nicht 44.5 – 30.4 = 14.1 Prozentpunkte? (Teoman-Doganay)

Wir rechnen mit den ungerundeten Quoten 44.52 % und 30.35 %. Die Werte auf der Folie sind nur auf eine Nachkommastelle gerundet.

Werden in Fachbereich A also Männer benachteiligt? (Teoman-Doganay)

Dort besteht ein deutlicher Unterschied zugunsten der Frauen (82.4 % gegenüber 62.1 %). Ob das eine Benachteiligung ist, können wir nicht sagen. Dafür fehlen Angaben zur Qualifikation der Bewerbenden.

Warum habt ihr keinen Chi-Quadrat-Test gemacht? (Filip)

Hypothesentests kommen im Kurs erst später. Wir beurteilen deshalb beschreibend mit der Definition der Unabhängigkeit aus dem Folienskript. Ein Test wäre der nächste Schritt, um zu prüfen, ob die kleinen Abweichungen in B bis F zufällig sind.

Was ist das Simpson-Paradoxon in einem Satz? (Filip)

Ein Zusammenhang, der innerhalb von Gruppen gilt, kann sich umkehren, wenn man die Gruppen zusammenfasst, weil eine Drittvariable, hier der Fachbereich, mit beiden Merkmalen zusammenhängt.

Warum ein Generator statt einer normalen Liste? (Leorat)

Ein Generator berechnet jedes Ergebnis erst, wenn es gebraucht wird (Lazy Evaluation). Bei sechs Fachbereichen spielt das für den Speicher keine Rolle. Wir zeigen damit aber das Konzept aus McKinney, S. 77–78, an einer echten Stelle im Code.

Warum partial und nicht einfach eine Lambda-Funktion? (Leorat)

Beides wäre möglich. Mit partial sieht man direkt, dass nur das Argument geschlecht fest gesetzt wird. Das ist lesbarer, und genau dieses Konzept beschreibt McKinney als Currying.

Warum fangt ihr nur den ValueError ab? (Leorat)

Ein ValueError entsteht, wenn ein Tabellenwert kein gültiger Text für eine Zahl ist, also bei einem Tippfehler. Andere Fehler wie ein TypeError deuten auf einen echten Programmfehler hin und sollen sichtbar bleiben (McKinney, S. 80).

Wie aussagekräftig ist eine Korrelation mit nur sechs Punkten? (Teoman-Doganay)

Sie beschreibt den Zusammenhang nur für diese sechs Fachbereiche und ist kein Beweis für eine Ursache. Zusammen mit Folie 12 zeigt sie aber klar: Frauen bewarben sich häufiger dort, wo die Quoten tief sind.

Was bedeutet «bei gleicher Fachbereichswahl» genau? (Filip)

Wir gewichten die Quoten beider Geschlechter mit derselben Verteilung, nämlich der aller Bewerbungen: A 20.6 %, B 12.9 %, C 20.3 %, D 17.5 %, E 12.9 %, F 15.8 %. So bleibt nur der Unterschied innerhalb der Fachbereiche übrig.

Tipps für den Auftritt

- Zeigt beim Sprechen auf die jeweilige Zahl oder den Balken, über den ihr redet.
- Übergaben klar ansagen («Damit übergebe ich an ...») und kurz Blickkontakt zur nächsten Person.
- Formeln langsam vorlesen: «P von Z geschnitten W» statt Symbole zu überspringen.
- Bei Fragen, die ihr nicht sicher beantworten könnt: ehrlich sagen, was die Daten zeigen und was nicht.