



School of
Management and Law

Statistik (w.BA.XX.2Stat-WIN.XX)

Newbold, Carlson, Thorne: Statistics for Business and Economics,
8. Auflage, Kapitel 1

Teil 1: Tabellen und Diagramme



Building Competence. Crossing Borders.

Copyright © 2013 Pearson Education, Inc. Publishing as Prentice Hall.

Verantwortlich martin.schnauss@zhaw.ch

Lernziele:

Nach Bearbeitung des Teil 1 können Sie:

- erklären, wie Entscheidungen oft auf unvollständigen Informationen beruhen.
- wichtige Definitionen und Unterscheidungen erläutern:
 - Grundgesamtheit/Population vs. Stichprobe
 - Parameter vs. Statistik
 - Deskriptive vs. schliessende Statistik
- darlegen, was man unter einer (reinen) Zufallsstichprobe versteht.
- Datentypen und Skalierungen identifizieren.
- Diagramme und Tabellen erstellen und interpretieren, welche
 - kategoriale (qualitative) Daten beschreiben.
 - Daten im Zeitablauf darstellen.
 - metrische (quantitative) Daten beschreiben.
- Beziehungen zwischen Variablen beschreiben.
- geeignete und unsachgemässe Verfahren beschreiben, Daten graphisch darzustellen.

§ 1 Umgang mit Unsicherheit

- Alltägliche Entscheidungen basieren auf *unvollständigen Informationen*.
Beispiele:
 - In welcher Verfassung wird der Arbeitsmarkt sein, wenn ich mein Studium abgeschlossen habe?
 - Wird der Aktienpreis von UBS in 6 Monaten höher sein als heute?
 - Werden die Zinssätze trotz prognostizierten Budgetdefiziten des Bundeshaushaltes tief bleiben?
- *Daten werden gebraucht, um die Entscheidungsfindung zu unterstützen.*
- Die Statistik ist ein Instrument, das uns hilft, Daten
 - zu **verdichten**,
 - zu **analysieren** und
 - zu **interpretieren**.


Zentrale Begriffe

- Eine **Population (Grundgesamtheit)** ist die Menge aller statistischen Einheiten bzw. Merkmalsträger, für die wir uns interessieren bzw. welche wir untersuchen.
 - N ist dabei die Populationsgrösse.
- Eine **Stichprobe** ist eine beobachtete Teilmenge der Population.
 - n ist dabei die Stichprobengrösse.
- Die **einfache Zufallsauswahl** ist ein Verfahren, bei dem *jede mögliche Stichprobe von n Elementen gleich wahrscheinlich* ist. Die Resultierende Stichprobe wird (reine) **Zufallsstichprobe** genannt.
- Ein **Parameter** ist eine spezifische Charakteristik einer Population.
- Eine **Statistik** ist eine spezifische Charakteristik einer Stichprobe.

Population versus Stichprobe

Grundgesamtheit bzw. Population


$$N = 42$$



Werte, die aus einer Population berechnet werden, nennt man **Parameter**.

Stichprobe

$$n = 7$$



Werte, die aus einer Stichprobe berechnet werden, nennt man **Statistiken**.


- Beispiele von Populationen: Alle Wahlberechtigten in einem Land, alle Erwerbstätigen in der Schweiz, alle Anlagefonds der UBS

Zwei Teilbereiche der Statistik:

Deskriptive versus schliessende Statistik

- **Deskriptive (auch beschreibende) Statistik**
 - Graphische und numerische Verfahren, Daten zu verarbeiten und zu verdichten
 - Datenerhebung (z.B. Umfrage)
 - Daten verdichten und präsentieren (Tabellen, Diagramme, Kennzahlen)
- **Schliessende (auch inferentielle oder induktive) Statistik**
 - Konklusionen bzw. Entscheidungen bezüglich einer Population basierend auf Stichproben-Auswertungen.
 - **Schätzverfahren**
Beispiel: Durchschnittslohn einer Population wird mittels eines Stichproben-durchschnitts geschätzt.
 - **Hypothesentests**
Beispiel: Die Behauptung wird geprüft, dass der Durchschnittslohn der Population 5 000 CHF betrage.

§ 2 Datentypen



Skalen- bzw. Messniveau

Abstände bestimmbar,
absoluter Nullpunkt

Verhältnisskala

Abstände bestimmbar,
aber kein absoluter
Nullpunkt

Intervallskala

Kategorien mit
Rangordnung

Ordinalskala

Kategorien (ohne
Ordnung/Richtung)

Nominalskala

quantitative Daten

qualitative Daten

Beispiel aus **Business Intelligence Modul**

Label

- Wir können auch kontinuierlich skalierte Labels auf eine Nominalskala reduzieren, wenn dies aus Anwendungsperspektive ausreicht.
- Zum Beispiel können wir die Prognose des Wohlbefindens eines Menschen wie folgt prognostizieren:
 - Menge ausgeschütteten Dopamin/Serotonin/Endorphine etc. (kontinuierliche Skala)
 - Auf einer Skala von 1 bis 10 (Ordinalskala)
 - 😊 oder ☹ oder (Nominalskala)
- Oft ist aus Sicht einer Anwendung oder eines angestrebten Erkenntnisgewinns klar, wie die Labels gestaltet sein sollen.


§ 3 - § 6 Darstellung von Daten

- Daten in *Rohform* sind üblicherweise *ungeeignet* für die Entscheidungsfindung.
- Das Datenmaterial muss irgendwie *aufbereitet bzw. übersichtlich dargestellt* werden. Hierzu eignen sich
 - **Tabellen** und
 - **Graphen.**
- Das geeignete Diagramm zur Darstellung der Daten *hängt vom Datentyp* ab.
- Wir betrachten zuerst Darstellungsformen für
 - **kategoriale Variablen**und danach solche für
 - **metrische Variablen.**

Beispiel aus **Business Intelligence Modul**

Neuronale Netze

Das Datenmaterial muss irgendwie *aufbereitet bzw. übersichtlich dargestellt* und interpretierbar gemacht werden:



Beispiel aus Business Intelligence Modul







Neuronale Netze

Das Datenmaterial muss irgendwie *aufbereitet bzw. übersichtlich dargestellt* und interpretierbar gemacht werden:

Height	Weight	Body Fat	Sugar	Diabetic?
72	195	50	72	1
60	165	60	60	0
75	215	45	75	1
68	170	15	68	1
65	155	20	65	0
74	200	08	74	0

Height	Weight	Body Fat	Sugar	Diabetic?
72	195	50	72	1
60	165	60	60	0
75	215	45	75	1
68	170	15	68	1
65	155	20	65	0
74	200	08	74	0

Height	Weight	Body Fat	Sugar	Diabetic?
72	195	50	72	1
60	165	60	60	0
75	215	45	75	1
68	170	15	68	1
65	155	20	65	0
74	200	08	74	0



Quelle: <https://www.youtube.com/watch?v=eK9B0m8BB3o&feature=youtu.be>

Beispiel aus **Business Intelligence Modul**

Neuronale Netze

Video-Tutorials für den Einstieg (im nächsten / übernächsten Semester):


1. Weights and Loss:
https://www.youtube.com/watch?v=oFTpK_v9llw
2. Activation Functions:
https://www.youtube.com/watch?v=f8m0e_Dhd5o
3. Bias: <https://www.youtube.com/watch?v=LnLGZxE5GX4>
4. Training: <https://www.youtube.com/watch?v=eK9B0m8BB3o>
5. Tesla-Style Autopilot:
<https://www.youtube.com/watch?v=l8BohsJ-Q0Q>

The BAI Summer School on Data Science

The [Business Analytics Institute](#), together with the [ZHAW Datalab](#) of Zurich University of Applied Sciences, will once again be offering a 10-day summer school on our Basque Coast campus in Bayonne on the Practice of Data Science.



§ 3 Tabellen und Diagramme für kategoriale Daten




Häufigkeitstabelle

- Die **Häufigkeitstabelle** fasst die (absoluten oder relativen) *Häufigkeiten pro Kategorie* zusammen.
- Beispiel: Patienten nach Spitalabteilung pro Jahr

Spitalabteilung	Anzahl_Patienten	in_Prozent
Herzlinik	1052	11.93%
Notfallstation	2245	25.46%
Intensivstation	340	3.86%
Frauenklinik	552	6.26%
Chirurgie	4630	52.50%
	8819	100.01%

Variablen sind
kategorial




Die Summe der Kategorienwerte weicht
infolge Rundens von 100.0% ab.

Säulen- und Balkendiagramm

- Säulendiagramme bzw. Balkendiagramme werden oft bei qualitativen (kategorialen) Daten eingesetzt.
- Die **Höhe der Säulen (bzw. Länge der Balken)** ist *proportional* zur absoluten bzw. relativen Häufigkeit jeder Kategorie.
- Beispiel:


Spitalabteilung	Anzahl_Patienten	in_Prozent
Herzklinik	1052	11.93%
Notfallstation	2245	25.46%
Intensivstation	340	3.86%
Frauenklinik	552	6.26%
Chirurgie	4630	52.50%
	8819	100.01%



Kreisdiagramm

- Das Kreisdiagramm (auch Torten- oder Kuchendiagramm) eignet sich ebenfalls, um kategoriale Daten darzustellen.
- Die **Fläche der Kreissektoren ist *proportional* zur absoluten bzw. relativen Häufigkeit jeder Kategorie.**
- Beispiel:


Spitalabteilung	Anzahl_Patienten	in_Prozent
Herzklinik	1052	11.93%
Notfallstation	2245	25.46%
Intensivstation	340	3.86%
Frauenklinik	552	6.26%
Chirurgie	4630	52.50%
	8819	100.01%




Kreisdiagramm: Beispiele aus der Literatur

Unternehmensgrösse¹ 2008

Unternehmen nach Grössenklassen



Beschäftigte nach Unternehmensgrösse



¹ Nur marktwirtschaftliche Unternehmen. Die Grösse der Unternehmen bemisst sich nach der Zahl der Vollzeitäquivalente (Teilzeit- auf Vollzeitstellen umgerechnet).

Quelle: BFS, Taschenstatistik der Schweiz 2013

Fakultativ: Pareto-Diagramm

- Wird ebenfalls benutzt, um kategoriale Daten darzustellen.
 - Es handelt sich um ein Säulendiagramm, bei dem die Kategorien in **absteigender Reihenfolge bezüglich Häufigkeit** angeordnet werden.
 - Im gleichen Diagramm wird oft noch die **Pareto-Kurve** dargestellt.
 - **Das Diagramm wird eingesetzt, um die «wenigen wichtigen» von den «vielen unwichtigen» Faktoren zu unterscheiden.**
- Beispiel: 400 defekte Produkte werden nach der Ursache des Mangels untersucht.

Ursache	Häufigkeit
Mangelhafte Verschweissung	34
Schlechte Justierung	223
Fehlendes Teil	25
Lackierfehler	78
Elektrischer Kurzschluss	19
Gerissenes Gehäuse	21


Pareto-Diagramm (Forts.)

1. Schritt: Nach Häufigkeit absteigend sortieren
2. Schritt: Relative Häufigkeiten berechnen
3. Schritt: Für die **Pareto-Kurve die *kumulierten* (relativen) Häufigkeiten** berechnen

Ursache	Haeufigkeit	in_Prozent	Kumulativ
Schlechte Justierung	223	55.75%	55.75%
Lackierfehler	78	19.50%	75.25%
Mangelhafte Verschweissung	34	8.50%	83.75%
Fehlendes Teil	25	6.25%	90.00%
Gerissenes Gehäuse	21	5.25%	95.25%
Elektrischer Kurzschluss	19	4.75%	100.00%
	400	100.00%	

Pareto-Diagramm (Forts.)


4. Graphische Darstellung der Resultate




Beispiel zum Säulendiagramm: Notenverteilung

- Mit Balkendiagrammen lassen sich auch ordinalskalierte Daten (und diskrete mit wenigen Ausprägungen) darstellen.
- Beispiel: Notenverteilung in einer Statistik Prüfung (Hinweis: Noten sind ordinalskaliert. Sie werden aber oft auch als metrische Grösse behandelt.)

Note	Haeufigkeit	relative_Haeufigkeit	Kumulativ
1.5	4	1.32%	1.32%
2	5	1.64%	2.96%
2.5	17	5.59%	8.55%
3	25	8.22%	16.77%
3.5	41	13.49%	30.26%
4	83	27.30%	57.56%
4.5	62	20.39%	77.95%
5	39	12.83%	90.78%
5.5	17	5.59%	96.37%
6	11	3.62%	99.99%
	304	99.99%	



§ 4 - § 5 Diagramme zur Darstellung metrischer Daten



§ 4 Diagramm für Zeitreihendaten

- Ein **Liniendiagramm (Zeitreihenplot)** wird gebraucht, um die *Wertentwicklung einer Variable über die Zeit* darzustellen.
- Die Zeit wird auf der horizontalen Achse (Abszisse) gemessen.
- Die Variable, für die man sich interessiert, wird auf der vertikalen Achse (Ordinate) gemessen.
- Beispiel:



Datenquelle: Finanzen.net

§ 5 Häufigkeitsverteilungen metrischer Daten

- Eine **Häufigkeitsverteilung** dient der übersichtlichen Beschreibung bzw. Darstellung von Daten.
- **Es handelt sich um eine Funktion, die allen Werten bzw. Wertegruppen eine Häufigkeit zuordnet.**
- Die Zuordnung kann unterschiedlich erfolgen, nämlich in Form
 - einer **Tabelle**,
 - eines **Diagramms** oder
 - einer **Funktionsgleichung**.
- Bei stetigen Merkmalen – oder diskreten Merkmalen mit sehr vielen Ausprägungen – ist es zweckmässig, die Merkmalsausprägungen zu *klassieren (gruppieren)*. Man spricht dann von einer **klassierten / gruppierten Häufigkeitsverteilung**.
 - Die **Verdichtung** der Daten bei Klassenbildung dient der besseren visuellen Interpretation der Daten (Übersichtlichkeit),
 - **reduziert** aber gleichzeitig den **Informationsgehalt (Zielkonflikt)**.

Häufigkeitsverteilung bei diskreten Merkmalen

- Beispiel: Haushaltsgrösse im Kanton Schwyz, Dezember 2011 (Quelle: BfS, Eidgenössische Volkszählung 2011)
 - Urliste (in Personen pro Haushalt): 3, 2, 1, 1, 2, 7, 4, 1, 2, ... ($N = 60'486$ Haushalte)
 - Eine Häufigkeitsverteilung schafft einen Überblick über die Daten, welche die (hier sehr lange) Urliste nicht ermöglicht.

Anzahl Personen pro Haushalt	Absolute Häufigkeit
1	18'415
2	20'373
3	8'291
4	8'718
5	3'305
6 oder mehr	1'384
Total	60'486

Häufigkeitsverteilung bei diskreten Merkmalen (Forts.)

Auszug aus: Eidgenössische Volkszählung 2011: Bestand und Struktur der Haushalte

cc-d-01.05.01.11 Privathaushalte¹⁾ nach Kanton und Haushaltsgrösse, am 31. Dezember 2011

Kanton	Total	Anzahl Haushalte mit					
		1 Person	2 Personen	3 Personen	4 Personen	5 Personen	6 oder mehr Personen
Luzern	158'761	51'796	51'963	20'204	22'095	8'881	3'822
Uri	14'120	4'094	4'864	1'792	2'109	916	345
Schwyz	60'486	18'415	20'373	8'291	8'718	3'305	1'384
Obwalden	14'406	4'366	4'640	1'943	2'209	832	416
Glarus	16'537	5'472	5'505	2'240	2'241	756	323
Zug	48'008	15'215	15'979	6'640	6'891	2'421	862
Solothurn	111'876	36'974	39'240	14'836	14'149	4'959	1'718
Basel-Stadt	94'864	45'718	27'864	10'028	7'737	2'582	935
Basel-Landschaft	120'471	38'623	43'615	16'178	15'667	4'775	1'613

Basis: Ständige Wohnbevölkerung am Hauptwohnsitz

© BFS - Statistisches Lexikon der Schweiz

Häufigkeitsverteilung bei diskreten Merkmalen (Forts.)

- Die (absoluten) Häufigkeitsverteilungen ermöglichen einen besseren Überblick über die Daten, als dies die (hier sehr langen) Urlisten ermöglichen würden.
- Wichtige **Strukturunterschiede** werden aber erst durch *relative* Häufigkeitstabellen ersichtlich. Wir stellen diese beispielhaft für die Kantone Uri und Basel Stadt dar.

Anzahl Personen pro Haushalt	Relative Häufigkeit	
	Uri	Basel-Stadt
1	29.0%	48.2%
2	34.4%	29.4%
3	12.7%	10.6%
4	14.9%	8.2%
5	6.5%	2.7%
6 oder mehr	2.4%	1.0%

Die relativen Häufigkeiten belegen die sehr unterschiedliche Struktur der Haushalte in den beiden Kantonen.

Häufigkeitsverteilungen bei stetigen Merkmalen (oder diskreten Merkmalen mit vielen Ausprägungen)

- Bei stetigen Merkmalen (sowie bei diskreten Merkmalen mit vielen Ausprägungen) ist es zwingend (vorteilhaft), die Daten für die Häufigkeitsverteilung zu gruppieren/klassieren.
- **Hinweise zur Klassenbildung:**
 - Jede Klasse hat (möglichst) die gleiche Breite.
 - Bestimmung der ...

$$\text{Klassenbreite} = \frac{\text{grösster Wert} - \text{kleinster Wert}}{\text{Anzahl gewünschter Klassen}}$$

- Klassenbreiten runden, um gewünschte Klassengrenzen zu erhalten
- Je nach Grösse des Datensatzes mind. 4-5 und meist nicht mehr als 15-20 Klassen einsetzen
- **Klassen überschneiden sich nie und es gibt keine Lücken.**

Beispiel einer klassierten Häufigkeitsverteilung

- Studierende einer Klasse der Grösse $N = 20$ haben folgende Punkte in einer schriftlichen Arbeit erzielt (Urliste):

36, 48, 21, 26, 33, 28, 21, 34, 30, 16, 14, 27, 8, 5, 30, 14, 22, 14, 27, 25

- Erstellung der klassierten Häufigkeitstabelle:
 - Daten aufsteigend sortieren (geordnete Urliste = Rangliste):

5, 8, 14, 14, 14, 16, 21, 21, 22, 25, 26, 27, 27, 28, 30, 30, 33, 34, 36, 48

- Anzahl gewünschter Klassen: 5
- Berechnete Klassenbreite = $(48 - 5)/5 = 8.6$
- Eine Klassenbreite von 10 (beginnend bei 0 Punkten) drängt sich auf.
Klassengrenzen: 0 bis unter 10, $10 < 20$, $20 < 30$, $30 < 40$, $40 < 50$
- Schliesslich werden die Häufigkeiten den Klassen zugeteilt.

Beispiel einer klassierten Häufigkeitsverteilung (Forts.)

- Geordnete Urliste:

Obs	_NAME_	COL1	COL2	COL3	COL4	COL5	COL6	COL7	COL8	COL9	COL10	COL11	COL12	COL13	COL14	COL15	COL16	COL17	COL18	COL19	COL20
1	Uhrzeit	5	8	14	14	14	16	21	21	22	25	26	27	27	28	30	30	33	34	36	48

- Klassierte Häufigkeitstabelle:

Die Prozedur FREQ

Punkte	Häufigkeit	Prozent	Kumuliert Häufigkeit	Kumuliert Prozent
0 bis unter 10	2	10.00	2	10.00
10 bis unter 20	4	20.00	6	30.00
20 bis unter 30	8	40.00	14	70.00
30 bis unter 40	5	25.00	19	95.00
40 bis unter 50	1	5.00	20	100.00

Histogramm


- Die graphische Darstellung der Häufigkeitsverteilung metrisch skalierten, in Klassen eingeteilter Daten nennt man **Histogramm**.
- Über den Klassen werden sich berührende Säulen abgetragen, welche *flächenproportional* zu den (relativen) Klassenhäufigkeiten sind.
- Bei gleichen Klassenbreiten sind die Säulen auch höhenproportional zu den (relativen) Klassenhäufigkeiten. Deshalb sollte man möglichst gleiche Klassenbreiten wählen.
- Manchmal sind breitere Klassen (insbesondere am oberen Ende der Verteilung) angebracht, um nicht zu viele Klassen (bei Ausreißern) bilden zu müssen. Typischerweise geschieht dies bei Lohnverteilungen.

Histogramm: Beispiel


- Punkteverteilung einer Klasse an einer schriftlichen Arbeit:

Die Prozedur FREQ

Punkte	Häufigkeit	Prozent	Kumuliert Häufigkeit	Kumuliert Prozent
0 bis unter 10	2	10.00	2	10.00
10 bis unter 20	4	20.00	6	30.00
20 bis unter 30	8	40.00	14	70.00
30 bis unter 40	5	25.00	19	95.00
40 bis unter 50	1	5.00	20	100.00



(keine Lücken
zwischen den
Säulen)



Fragen im Zusammenhang mit der Klassenbildung

1. Wie breit sollte jede Klasse sein?



(Wie viele Klassen sollten gebildet werden?)

2. Wie sollten die Klassengrenzen festgelegt werden?

- Oft durch Ausprobieren und Beurteilung des Ergebnisses
- Das Ziel besteht darin, eine Verteilung darzustellen, welche weder zu «gezackt» noch zu «blockig» ist.
- Die Struktur der Variation in den Daten soll möglichst angemessen dargestellt werden.

Fragen im Zusammenhang mit der Klassenbildung (Forts.)

- **Zu viele (zu schmale) Klassen**
 - Können zu einer sehr «zerklüfteten» Verteilung führen mit Lücken aus leeren Klassen.
 - Können einen irreführenden Eindruck bezüglich der Verteilung der Daten geben.
- **Zu wenige (zu breite) Klassen**
 - Können die Variation der Daten zu stark komprimieren und ein zu «blockiges» Bild der Verteilung liefern.
 - Können wichtige Muster der Verteilung verschleiern.



Kumulierte Häufigkeitsverteilung

Punkte	Häufigkeit	Prozent	Kumuliert Häufigkeit	Kumuliert Prozent
0 bis unter 10	2	10.00	2	10.00
10 bis unter 20	4	20.00	6	30.00
20 bis unter 30	8	40.00	14	70.00
30 bis unter 40	5	25.00	19	95.00
40 bis unter 50	1	5.00	20	100.00

- Verständnisfragen (betrachten Sie vorerst nur die kumulierten Häufigkeiten)
 - Wie viele Studierende hatten weniger als 30 Punkte?
 - Wie viele Studierende hatten mindestens 30 Punkte?
 - Welcher Anteil der Studierenden hatte mindestens 20, aber weniger als 40 Punkte?



Die Ogive

- **Die graphische Darstellung der kumulierten Häufigkeitsverteilung nennt man Ogive.**
 - Falls die Daten von einer Stichprobe stammen, entspricht die Ogive der empirischen Verteilungsfunktion (Verteilungsfunktion der Stichprobe).
 - Falls die Daten aus einer Vollerhebung stammen, entspricht die Ogive der Verteilungsfunktion, welche in späteren Kapiteln genauer thematisiert wird.
- Die Ogive kann sowohl für *diskrete* als auch *stetige* Merkmale erstellt werden.
- Die Ogive kann (wie schon das Histogramm) sowohl für kumulierte *absolute* als auch kumulierte *relative* Häufigkeiten erstellt werden.

Die Ogive: Beispiel

Punkte	Häufigkeit	Prozent
0 bis unter 10	2	10.00
10 bis unter 20	4	20.00
20 bis unter 30	8	40.00
30 bis unter 40	5	25.00
40 bis unter 50	1	5.00


Hinweis: Das theoretische Punkteminimum ist 0.



- **Verständnisfrage:**
Etwa welche Punktzahl wurde von der Hälfte der Studierenden nicht erreicht?

Beziehungen zwischen Variablen

- Die bisher besprochenen Tabellen und Diagramme haben nur eine einzige Variable umfasst.
- **Beziehungen** zwischen **zwei Variablen** können ebenfalls durch geeignete Tabellen bzw. Diagramme dargestellt werden.



Kreuztabellen (Kontingenztafeln)

- Eine Kreuztabelle (Kontingenztafel) stellt die kombinierte Häufigkeitsverteilung *zweier Variablen* dar.
- Sie ist die Erweiterung der Häufigkeitstabelle bei zwei Variablen.
- Kreuztabellen stellen (in der einfachsten Form) die absoluten oder relativen *Häufigkeiten für jede Kombination der Merkmalsausprägungen von zwei Variablen* dar.
- Falls es *r* Kategorien einer ersten Variable (Reihe) und *s* Kategorien einer zweiten Variable (Spalten) gibt, nennt man die Tabelle eine *(r × s) –Kreuztabelle*.


Kreuztabellen (Kontingenztafeln): Beispiel

- Aussereheliche Affären (Männer und Frauen zusammen)
Fair, R. C. (1978) A Theory of Extramarital Affairs. *Journal of Political Economy*, Februar 1978, 45-61.
- Variable 1: Aussereheliche Affäre im letzten Jahr (nein, ja)
- Variable 2: Religiosität (1=Atheist bis 5=sehr religiös)

Table of Affaere by Status						
Affaere	Status					Total
	1	2	3	4	5	
no	28 58.33	123 75.00	86 66.67	157 82.63	57 81.43	451
yes	20 41.67	41 25.00	43 33.33	33 17.37	13 18.57	150
Total	48	164	129	190	70	601


Graphische Darstellung multivariater kategorialer Daten: Gruppiertes Säulendiagramm

- **Gruppierte Säulendiagramme** sind geeignet, Kreuztabellen graphisch darzustellen:



Graphische Darstellung multivariater kategorialer Daten: Gestapeltes Säulendiagramm

- Die gleichen Daten lassen sich auch mit einem *gestapelten Säulendiagramm* darstellen:




Gruppiertes Balkendiagramm: Beispiel

- Im Gegensatz zum Säulendiagramm werden beim Balkendiagramm die Balken waagrecht abgetragen.

Erholungs- und Grünanlagen nach Nutzungsart
1985, 1997 und 2009

G 9




Quelle: BFS – Arealstatistik

© BFS

Streudiagramm


- **Streudiagramme** werden benutzt, um *gepaarte* Daten zweier *metrischer* Variablen darzustellen.
- Beispiel: Prüfungsergebnisse einer Klasse (13 Studierende, BF-PiE) an der SML in den Fächern Statistik und Quantitative Methoden:



Streudiagramm: Weiteres Beispiel

- Was lesen Sie aus dem Diagramm?

Schweiz: «Zeitbudget» der Studierenden FH während der Vorlesungszeit nach Fachbereichsgruppe und Art der Aktivität (Mittelwert in Stunden/Woche)



Quelle: Soziale Lage der Studierenden 2005


© Bundesamt für Statistik (BFS)

§ 6 Fehler in der Darstellung von Daten

Ziele einer effektiven Datendarstellung:

- Daten so darstellen, dass die *wesentlichen* Informationen ersichtlich sind.
- Komplexe Sachverhalte *klar und genau* darstellen.
- *Verzerrungen vermeiden*, welche falsche Eindrücke der Daten vermitteln können.
 - Insbesondere müssen *Proportionen* korrekt wiedergegeben werden.
 - Histogramme mit *unterschiedlichen* Klassenbreiten sind nicht *höhenproportional* zu den Häufigkeiten.
 - Abszisse oder Ordinate verdichten oder vergessen.


Fehler in der Darstellung von Daten: 1. Beispiel



Entwicklung des Hausmülls in Deutschland: Einmal rasant rauf, dann wieder runter, so wollen es die Autoren des Magazins sehen

Quelle: http://www.bissantz.de/pub/Luegen_mit_Statistiken.pdf


Fehler in der Darstellung von Daten: 1. Beispiel (Forts.)



Faire Darstellungen stellen Proportionalität zwischen Flächen- und Wertänderungen her, die Originalgrafik ist davon um den Faktor 19 entfernt

Quelle: http://www.bissantz.de/pub/Luegen_mit_Statistiken.pdf


Fehler in der Darstellung von Daten: 2. Beispiel



Bundeswehretat im Sturzflug oder doch nur stabiler Haushalt in Zeiten enger Budgets?

Quelle: http://www.bissantz.de/pub/Luegen_mit_Statistiken.pdf

Fehler in der Darstellung von Daten: 2. Beispiel (Forts.)



Der Wehretat blieb in den letzten fünf Jahren nahezu gleich, nicht mehr und nicht weniger sagen uns diese Daten, alles andere ist Politik

Quelle: http://www.bissantz.de/pub/Luegen_mit_Statistiken.pdf


Histogramme mit unterschiedlichen Klassenbreiten

- Unterschiedliche Klassenbreiten werden manchmal bei schiefen Verteilungen bzw. Verteilungen mit Ausreissern verwendet, damit nicht zu viele Klassen definiert werden müssen.
- Beispiel: Marktkapitalisierung der 80 Unternehmungen im SPI Middle am 24.1.2014, in Mrd. CHF (Quelle: SIX, Swiss Exchange)

Marktkapitalisierung (in Mrd. CHF)	Absolute Häufigkeit	Relative Häufigkeit
0 bis unter 0.5	13	16.25%
0.5 bis unter 1.0	17	21.25%
1.0 bis unter 1.5	12	15.00%
1.5 bis unter 2.0	9	11.25%
2.0 bis unter 2.5	7	8.75%
2.5 bis unter 9.5	22	27.50%
Total	80	100.00%

Histogramme mit unterschiedlichen Klassenbreiten (Forts.)

- **Falsche Darstellung** der Daten: Flächen sind nicht proportional zu den (relativen) Häufigkeiten.



Histogramme mit unterschiedlichen Klassenbreiten (Forts.)

- Wir berechnen die sogenannte Häufigkeitsdichte, um die Balken des Histogramms flächenproportional zu den (relativen) Häufigkeiten zu erhalten.

Marktkapitalisierung (in Mrd. CHF)	Relative Häufigkeit	Häufigkeitsdichte (f_i/n)/ Klassenbreite
0 bis unter 0.5	16.25%	0.325
0.5 bis unter 1.0	21.25%	0.425
1.0 bis unter 1.5	15.00%	0.300
1.5 bis unter 2.0	11.25%	0.225
2.0 bis unter 2.5	8.75%	0.175
2.5 bis unter 9.5	27.50%	0.039

Histogramme mit unterschiedlichen Klassenbreiten (Forts.)

- **Korrekte Darstellung** der Daten: Flächen sind nun proportional zu den (relativen) Häufigkeiten.

