



School of
Management and Law

Statistik (w.BA.XX.2Stat-WIN.XX)

Teil 2: Statistische Kennzahlen

Newbold, Carlson, Thorne: Statistics for Business and Economics, 8. Auflage
Kapitel 2: Statistische Kennzahlen



Building Competence. Crossing Borders.

Copyright © 2013 Pearson Education, Inc. Publishing as Prentice Hall.


Verantwortlich martin.schnauss@zhaw.ch

Lernziele:

Nach Bearbeitung dieses Teils können Sie:

- den Modus, den Median, das arithmetische Mittel und das geometrische Mittel berechnen und interpretieren.
- die Spannweite, den Interquartilsabstand, die Varianz, die Standardabweichung und den Variationskoeffizienten aus Daten ermitteln und deuten.
- beliebige Quantile bestimmen und interpretieren.
- einen Boxplot interpretieren.
- die Tschebyscheff-Ungleichung und das empirische Gesetz verstehen und anwenden.
- die Kovarianz und den Korrelationskoeffizienten berechnen und interpretieren.

§ 1 Lagemasse: Überblick



Arithmetisches Mittel (AM)

- Das arithmetische Mittel („Durchschnitt“) ist das am meisten benutzte Mass zur Beschreibung der zentralen Lage einer Verteilung.

- Für eine **Grundgesamtheit** (Population) mit N Werten:

$$\mu = \frac{\sum_{i=1}^N x_i}{N} = \frac{x_1 + x_2 + \dots + x_N}{N}$$

Populationswerte

Populationsgrösse

- Für eine **Stichprobe** der Grösse n :



$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

beobachtete Werte

Stichprobengrösse



Arithmetisches Mittel (Forts.)

- Berechnung: Summe der Werte dividiert durch die Anzahl der Werte
- Wird durch **Ausreisser** (extreme Werte) stark beeinflusst.



Median (Zentralwert)

- In einer **geordneten** Liste steht der Median genau in der **Mitte**.



- Robuste Statistik:** Der Median wird durch Ausreisser (extreme Werte) nicht beeinflusst.
- Der Median wird bei **quantitativen** und **ordinalskalierten** Daten eingesetzt.

Bestimmung des Median

- **Position des Median** in der Rangliste (geordnete Urliste):



$$\text{Rangzahl} = \frac{n+1}{2} \quad (\text{Position in der Rangliste})$$

- Bei **ungerader** Anzahl Beobachtungen ist der Median der Wert in der Mitte der Rangliste.
- Bei **gerader** Anzahl Beobachtungen ist der Median der Durchschnitt der zwei mittleren Werte in der Rangliste.

☞ Beachten Sie, dass $(n+1)/2$ nicht der Median selber, sondern lediglich die **Position** des Median in der Rangliste ist.

Modus

- Der Modus ist derjenige Wert, der am **häufigsten** auftritt.
- Der Modus kann bereits in der **Nominalskala** bestimmt werden.
- Möglich, dass es keinen Modus gibt oder dass es mehrere Modi gibt.




kein Modus
(oder alle Werte)

Einfaches Beispiel zu den Lagemassen

- Fünf Häuser auf einem Hügel am Strand

Haus	Preise_in_USD
Obs1	2000000
Obs2	500000
Obs3	300000
Obs4	100000
Obs5	100000
	3000000



Beispiel zu den Lagemassen (Forts.)

Haus	Preise_in_USD
Obs1	2000000
Obs2	500000
Obs3	300000
Obs4	100000
Obs5	100000
	3000000

Part of the «*Proc Univariate*» Output:

Basic Statistical Measures			
Location		Variability	
Mean	600000.0	Std Deviation	800000
Median	300000.0	Variance	6.4E11
Mode	100000.0	Range	1900000
		Interquartile Range	400000

Weitere statistische Auswertungen – als Vorgeschmack....

Moments			
N	5	Sum Weights	5
Mean	600000	Sum Observations	3000000
Std Deviation	800000	Variance	6.4E11
Skewness	2.00683594	Kurtosis	4.13012695
Uncorrected SS	4.36E12	Corrected SS	2.56E12
Coeff Variation	133.333333	Std Error Mean	357770.876

Basic Statistical Measures			
Location		Variability	
Mean	600000.0	Std Deviation	800000
Median	300000.0	Variance	6.4E11
Mode	100000.0	Range	1900000
		Interquartile Range	400000

Tests for Location: Mu0=0				
Test	Statistic		p Value	
Student's t	t	1.677051	Pr > t	0.1688
Sign	M	2.5	Pr >= M	0.0625
Signed Rank	S	7.5	Pr >= S	0.0625

Level	Quantile
100% Max	2000000
99%	2000000
95%	2000000
90%	2000000
75% Q3	500000
50% Median	300000
25% Q1	100000
10%	100000
5%	100000
1%	100000
0% Min	100000

Extreme Observations			
Lowest		Highest	
Value	Obs	Value	Obs
100000	5	100000	4
100000	4	100000	5
300000	3	300000	3
500000	2	500000	2
2000000	1	2000000	1


Welches ist das „beste“ Lagemass?

- Das häufigst benutzte Lagemass bei metrischen Daten ist das arithmetische Mittel.
- In schiefen Verteilungen ist der Median dem arithmetischen Mittel vorzuziehen.
 - ☞ Beispiel: Das Bundesamt für Statistik publiziert üblicherweise den Medianlohn und nicht den „Durchschnittslohn“, der viel höher ist.
- Der Median kann im Gegensatz zum arithmetischen Mittel auch für ordinalskalierte Daten bestimmt werden.
- Der Modus kann auch für nominalskalierte Werte ermittelt werden.
- Oft werden mehrere Lagemasse ausgewiesen, da man dadurch Hinweise zur Schiefe der Verteilung erhält (siehe folgende Folie).

Lagemasse in der Presse: Beispiel

Väter werden immer älter

Eheliche Lebendgeburten nach Alter des Vaters, 1979 und 2012



QUELLE: BFS

NZZ-INFOGRAFIK/lea.

Quelle: NZZ, 11.12.2013

Hinweis: Es handelt sich um Daten aus der Schweiz.

- Welches Lagemass wurde in der Abbildung für beide Verteilungen angegeben?
Modus. Der Median müsste die Verteilungen in zwei gleiche Hälften teilen, wäre also grösser. Der AM müsste noch höher liegen (Schwerpunkt).
- Die zwei Verteilungen sind rechtsschief bzw. linkssteil.
- Die nächste Folie geht kurz auf die Schiefe einer Verteilung ein.


Die Schiefe einer Verteilung

Die **Schiefe einer Verteilung** wird wie folgt unterschieden:

- linksschief bzw. rechtssteil
- symmetrisch
- rechtsschief bzw. linkssteil


linksschief

AM < Median




symmetrisch

AM = Median



rechtsschief

Median < AM



Geometrisches Mittel

- Das geometrische Mittel wird hauptsächlich benutzt, um die **durchschnittliche Wachstumsrate über die Zeit** zu berechnen

$$\bar{x}_g = \sqrt[n]{(x_1 \cdot x_2 \cdot \dots \cdot x_n)} = (x_1 \cdot x_2 \cdot \dots \cdot x_n)^{1/n}$$

- Geometrische **Durchschnittsrendite**:

$$\bar{r}_g = (q_1 \cdot q_2 \cdot \dots \cdot q_n)^{1/n} - 1$$

- wobei $q_i = (1 + r_i)$ dem **Wachstumsfaktor** in der Periode i entspricht.

Beispiel zum geometrischen Mittel

Eine Geldanlage von \$100 000 stieg bis Ende des ersten Anlagejahres auf \$150 000 und bis Ende des zweiten Anlagejahres auf \$180 000:

$$X_1 = \$100\,000 \quad X_2 = \$150\,000 \quad X_3 = \$180\,000$$



50% Anstieg

20% Anstieg

Wie hoch ist die durchschnittliche Jahresrendite?

Beispiel zum geometrischen Mittel (Forts.)

Arithmetisches
Mittel:

$$\bar{r} = \frac{(50\%) + (20\%)}{2} = 35\%$$

falsch bzw.
ungenau

Geometrisches
Mittel:

$$\begin{aligned}\bar{r}_g &= (q_1 \cdot q_2)^{1/2} - 1 \\ &= (1.50 \cdot 1.20)^{1/2} - 1 = (180/100)^{1/2} - 1 \\ &= 1.8^{1/2} - 1 = 1.34164 - 1 = 34.164\%\end{aligned}$$

korrekt

Überprüfen Sie das Resultat!

Quantile


- **Quantile** geben Positionen innerhalb einer Verteilung an.
- Das p -Quantil ist eine Kennzahl, welche die Verteilung in zwei Abschnitte unterteilt. $100p\%$ der Beobachtungen sind kleiner oder gleich dem p -Quantil und $100(1-p)\%$ grösser oder gleich.
 - Notation des p -Quantil: x_p
 - Beispiel: Das 50%-Quantil entspricht dem Median ($x_{0.50} = \text{Median von } x$).

Perzentile und Quartile

- **Perzentile** und **Quartile** sind Spezialfälle von Quantilen.
- Beispiele:
 - Das 10. Perzentil ist jener Wert der Verteilung, wo 10% der Werte links und 90% der Werte rechts davon liegen. Analog sind die anderen Perzentile definiert.
 - Das 50. Perzentil entspricht dem 50%-Quantil bzw. dem Median.
 - Das 1. Quartil ist jener Wert der Verteilung, wo 25% (ein Viertel) der Werte links und 75% der Werte rechts davon liegen. Analog sind die anderen Quartile definiert.
 - Das 2. Quartil entspricht dem 50%-Quantil bzw. dem Median.

Quartile

- Quartile teilen die geordneten Daten in 4 Segmente mit gleicher Anzahl Werte pro Segment auf.



- Das erste Quartil, Q_1 , ist derjenige Wert, bei welchem 25% der Beobachtungen kleiner und 75% grösser sind.
- Q_2 entspricht dem Median (50% der Werte sind kleiner, 50% grösser).
- Lediglich 25% der Beobachtungen sind grösser als das 3. Quartil.

Quartile (Forts.)

Quartile werden in der Rangliste (geordnete Urliste) durch „Positionsformeln“ bzw. die Ordnungszahl bestimmt:

- Position des 1. Quartils: $0.25(n+1)$
- Position des 2. Quartils: $0.50(n+1)$ (Position des Median)
- Position des 3. Quartils: $0.75(n+1)$

wobei n der Anzahl Beobachtungen entspricht.

Quartile (Forts.)

Beispiel: Bestimmung des 1. Quartils

geordnete Urliste: 11 12 13 16 16 17 18 21 22 (n = 9)




- Q_1 liegt an der Stelle $0.25(9+1) = 2.5$ in der Rangliste.
- Das 1. Quartil liegt somit zwischen der 2. und 3. Beobachtung und beträgt

$$Q_1 = 12.5$$

- Bestimmen Sie ebenso das 2. und 3. Quartil!

Quantile: Beispiel

- Beispiel aus der Presse (NZZ vom 11.10.2013):




Fünf-Punkte-Zusammenfassung

- Bei der **Fünf-Punkte-Zusammenfassung (five-number summary)** handelt es sich um 5 Statistiken, welche geordnet dargestellt werden:


$$\text{Minimum} < Q_1 < \text{Median} < Q_3 < \text{Maximum}$$

- Oft wird zusätzlich noch der arithmetische Mittelwert aufgeführt.

§ 2 Streuungsmasse: Überblick



Streuungs-masse informieren bezüglich der **Streuung** bzw. **Variabilität** der Daten einer Verteilung.




Gleiche Mittelwerte,
unterschiedliche Streuung

Spannweite

- Einfachstes Streuungsmass
- Differenz zwischen der höchsten und tiefsten Beobachtung:



$$\text{Spannweite} = X_{\max} - X_{\min}$$

Beispiel:



Nachteile der Spannweite

- Betrachtet lediglich die **Extremwerte** und nicht alle Daten der Verteilung:



- Reagiert somit empfindlich auf **Ausreisser** (keine *robuste* Statistik):

1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 4, 5

$$\text{Spannweite} = 5 - 1 = 4$$

1, 1, 1, 1, 1, 1, 1, 1, 1, 1, 2, 2, 2, 2, 2, 2, 2, 2, 3, 3, 3, 3, 4, 120

$$\text{Spannweite} = 120 - 1 = 119$$

Interquartilsabstand

- Der **Interquartilsabstand** (interquartile range, IQR) vermeidet das Problem mit den Ausreissern und ist somit eine *robuste Statistik*.
- Der IQR ignoriert die höchsten und tiefsten Beobachtungen durch die Berechnung der Spannweite der mittleren 50% der Daten.
- **Interquartilsabstand = 3. Quartil – 1. Quartil**

$$\text{IQR} = \Delta Q = Q_3 - Q_1$$

- Beispiele:

- 1, 1, 1, 1, 1, **1**, 1, 1, 1, 2, 2, **2**, 2, 2, 2, 2, 2, **3**, 3, 3, 3, 4, 5 ➡ IQR = 3 - 1 = 2
- 1, 1, 1, 1, 1, **1**, 1, 1, 1, 2, 2, **2**, 2, 2, 2, 2, 2, **3**, 3, 3, 3, 4, 120 ➡ IQR = 3 - 1 = 2

Boxplot


- Ein **Boxplot (box-and-whisker plot)** ist eine graphische Darstellung der Fünf-Punkte-Zusammenfassung.
- Die Graphik eignet sich insbesondere für den Vergleich von verschiedenen Verteilungen (z.B. Renditeverteilungen von Anlagefonds).
- Die “Box” geht vom 1. zum 3. Quartil und visualisiert den Interquartilsabstand. In der Box ist zudem der Median (2. Quartil) eingetragen.
- Zwei «Whiskers» (Fühler) reichen vom 1. und 3. Quartil zum minimalen und maximalen Wert.
 - Hinweis: Alternative Darstellungen des Boxplots sind ebenfalls gebräuchlich. Siehe hierzu die Legenden der entsprechenden Diagramme.

Boxplot (Forts.)

- Beispiele: Altersstruktur eines Fasnachtsvereins

12, 17, 30, 30, 32, 45, 49, 51, 57, 64, 70

μ




Ziel.

	Abs	lohn	...
Person			
Person 2			
...			
...			
...			

Häufigkeiten




min, Q_1 , Q_2 , Q_3 , max
"Median"
 μ



Varianz einer Grundgesamtheit

- Durchschnitt der quadrierten Abweichungen vom Mittelwert der Grundgesamtheit ~~$\sum (x_i - \mu)$~~



- Varianz einer Grundgesamtheit:**



wobei μ = Mittelwert der Grundgesamtheit
 N = Grösse der Grundgesamtheit
 x_i = i-te Beobachtung des Merkmals x

$$\sigma^2 = \frac{\sum_{i=1}^N (x_i - \mu)^2}{N}$$


- Alternativformel (Praktikerformel):**
(in Kap. 4 hergeleitet)

$$\sigma^2 = \left(\frac{1}{N} \sum_{i=1}^N x_i^2 \right) - \mu^2$$

Stichprobenvarianz

- (Approximativer) Durchschnitt der quadrierten Abweichungen vom Stichprobenmittelwert

- **Stichprobenvarianz:**



wobei

$\bar{x}$ = arithmetisches Mittel

n = Stichprobengrösse

x_i = i-te Beobachtung der Variable x

$$s^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1} = \frac{\left(\sum_{i=1}^n x_i^2 \right) - n\bar{x}^2}{n-1}$$

Standardabweichung

- Wichtigstes Streuungsmass
 - Zeigt die Streuung um den arithmetischen Mittelwert auf.
 - Hat die gleiche Masseinheit wie die Daten.
 - Kann (unter Vorbehalt) als durchschnittliche Abweichung der Daten vom Mittelwert interpretiert werden.
 - Standardabweichung der Grundgesamtheit
- σ_x , s_x auf dem TR

$x > 0$, x^2 , $\sqrt{x^2} = x$
Länge m^2 m

$$\sigma = \sqrt{\sigma^2} = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

Stichprobe

$$s = \sqrt{s^2} = \sqrt{\frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n-1}}$$

Stichprobenstandardabweichung: Berechnungsbeispiel

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$$

Stichprobendaten (x_i): 10, 12, 14, 15, 17, 18, 18, 24

$$n = 8 \quad \text{Mittelwert} = \bar{x} = 16$$

$$s = \sqrt{\frac{(10-16)^2 + (12-16)^2 + (14-16)^2 + \dots + (24-16)^2}{8-1}}$$

$$= \sqrt{\frac{130}{7}} = 4.31$$




Ein Mass für die
„durchschnittliche“
Abweichung vom
Mittelwert

Unterschiedliche Streuung


kleine Standardabweichung

grosse Standardabweichung




Vergleich von Standardabweichungen

Population A




$$\mu = 15.5$$
$$\sigma = 3.122$$

Population B



$$\mu = 15.5$$
$$\sigma = 0.866$$

Population C



$$\mu = 15.5$$
$$\sigma = 4.272$$

Einige Eigenschaften von Varianz und Standardabweichung

jeder x_i

- **Jeder Wert** im Datenset fließt in die Berechnung ein.
- Werte, die weit vom Mittelwert entfernt liegen, werden stark gewichtet (da *quadrierte* Abweichungen).
 - Varianz und Standardabweichung sind **nicht robust gegen Ausreisser**.
- Die Varianz/Standardabweichung hat weitreichende **theoretische Bedeutung**, insb. in der schliessenden Statistik, wie noch gezeigt wird.

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (x_i - \mu)^2}{N}}$$

Ziel: Normalverteilung beschreiben
 $N(\mu, \sigma^2)$

Variationskoeffizient

- Misst die Streuung **relativ zum arithmetischen Mittelwert** (in Prozent).
- Eignet sich, zwei oder mehr Datensätze mit (wesentlich) **unterschiedlichen Mittelwerten bzw. unterschiedlichen Masseinheiten zu vergleichen.**

$$CV = \left(\frac{s}{\bar{x}} \right) \cdot 100\%$$

Beispiel zum Variationskoeffizient

- **Kaffeepreise in einer Schweizer Stadt:**

- Durchschnittlicher Preis für einen Espresso CHF 4.25
- Standardabweichung = CHF 0.85


$$CV_{CH} = \left(\frac{s}{\bar{x}} \right) \cdot 100\% = \frac{\text{CHF } 0.85}{\text{CHF } 4.25} \cdot 100\% = 20\%$$

- **Kaffeepreise in einer italienischen Stadt:**

- Durchschnittlicher Preis € 1.20
- Standardabweichung = € 0.30

$$CV_{It} = \left(\frac{s}{\bar{x}} \right) \cdot 100\% = \frac{\text{€ } 0.30}{\text{€ } 1.20} \cdot 100\% = 25\%$$

- Der Variationskoeffizient ist einheitsfrei (einfacherer Vergleich).
- Obwohl die absolute Streuung (bei einem Eurokurs von 1.20 CHF/€) höher ist in der CH als in Italien, ist die relative Streuung in Italien leicht höher.



$$\sigma_1 < \sigma_2$$

Die Ungleichung von Tschebyscheff


Für **jede** Grundgesamtheit mit Mittelwert μ und Standardabweichung σ und Konstante $k > 1$ gilt, dass der Anteil der Werte, die in das Intervall

$$[\mu - k\sigma, \mu + k\sigma]$$

fallen, **mindestens**

$$1 - \frac{1}{k^2}$$

beträgt.



Die Ungleichung von Tschebyscheff (Forts.)

- Für $k > 1$ gilt: Mindestens $(1 - 1/k^2)$ der Werte liegen innerhalb k Standardabweichungen vom Mittelwert.
- Beispiel: Gegeben sei eine Population mit Mittelwert $\mu = 2.6$ und Standardabweichung $\sigma = 1.2$.
$$[\mu - 2 \cdot \sigma, \mu + 2 \cdot \sigma] = [2.6 - 2 \cdot 1.2, 2.6 + 2 \cdot 1.2] = [0.2, 5.0]$$
 - Mindestens wie viele Werte liegen innerhalb $\overset{k}{2}$ Standardabweichungen vom Mittelwert, also im Intervall $[0.2, 5.0]$?
 - Lösung: Da $k = 2 > 1$, somit mindestens $1 - 1/k^2 = 1 - 1/2^2 = 75\%$
 - Mindestens wie viele Werte liegen im Intervall $[0.8, 4.4]$?
 - Lösung: $k = 1.5 > 1$; somit mindestens $1 - 1/k^2 = 1 - 1/1.5^2 = 55.6\%$


Das empirische Gesetz

$$\mathcal{N}(\mu, \sigma^2)$$

Falls die Daten „glockenförmig“ verteilt sind, dann enthält das Intervall



$$\mu \pm \sigma$$

etwa **68%** der Werte in der Grundgesamtheit oder der Stichprobe.



Das empirische Gesetz (Forts.)

- $\mu \pm 2\sigma$ enthält etwa **95%** der Werte in der Grundgesamtheit oder der Stichprobe.
- $\mu \pm 3\sigma$ enthält praktisch alle (ca. **99.7%**) Werte in der Grundgesamtheit oder der Stichprobe.



z-Wert

- Der **z-Wert** (z-score) zeigt an, *wie viele Standardabweichungen* (σ) ein bestimmter Wert (x_i) unterhalb (falls $z < 0$) oder oberhalb (falls $z > 0$) des Mittelwertes (μ) liegt.


$$z = \frac{x_i - \mu}{\sigma}$$

☞ Der z-Wert ist dimensionslos.

z-Wert: Beispiel

- Der durchschnittliche Intelligenzquotient in einer Population beträgt 100 Punkte, die Standardabweichung 15 Punkte. Wie hoch ist der z-Wert eines IQ von 121?

$$z = \frac{x_i - \mu}{\sigma} = \frac{121 - 100}{15} = 1.4$$



- Interpretation: 121 Punkte sind 1.4 Standardabweichungen oberhalb des Mittelwertes.

§ 3 Gruppierte und klassierte Daten: Gewichtetes arithmetisches Mittel bei gruppierten Daten

- **Motivationsbeispiel:** Gesucht sei das arithmetische Mittel der folgenden numerischen Stichprobenwerte ($n = 10$):

1, 1, 1, 2, 2, 2, 2, 2, 3, 3

- Ein möglicher Lösungsweg wäre:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i = \frac{1}{10} (1 + 1 + 1 + 2 + 2 + 2 + 2 + 2 + 3 + 3) = \frac{19}{10} = 1.9$$

- Offensichtlich einfacher wäre aber das **gewichtete (oder gewogene) arithmetische Mittel**:

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i f_i = \frac{1}{10} (1 \cdot 3 + 2 \cdot 5 + 3 \cdot 2) = \frac{19}{10} = 1.9$$

Gewichtetes arithmetisches Mittel bei gruppierten Daten (Forts.)

Definition:

(Statistik)

$$\bar{x} = \frac{1}{n} \sum_{i=1}^k x_i f_i$$

(Parameter)

$$\text{bzw. } \mu = \frac{1}{N} \sum_{i=1}^k x_i f_i$$

- x_1 bis x_k sind die k verschiedenen Ausprägungen des Merkmals.
- f_i ist die *absolute Häufigkeit* der i -ten Ausprägung von x .
- Alternativ kann das gewichtete arithmetische Mittel auch mit *relativen Häufigkeiten* berechnet werden:

$$\bar{x} = \sum_{i=1}^k x_i \left(\frac{f_i}{n} \right)$$

- Es gilt $\sum_{i=1}^k f_i = n$ und $\sum_{i=1}^k \left(\frac{f_i}{n} \right) = 1$.

Gewichtetes arithmetisches Mittel bei gruppierten Daten (Forts.)

- Beispiel mit *absoluten* und *relativen* Häufigkeiten:

x_i	f_i	f_i/n	F_i/n
0	8	16%	16%
1	12	24%	40% = 16+24
2	18	36%	76%
3	10	20%	96%
4	2	4%	100%
Σ	50	100%	

- Zusatzfrage: Wie hoch wäre im Beispiel der Modus und der Median?

- Lösung:

- $Modus = 2$
(Wert mit höchster (rel.) Häufigkeit)

- $Median = 2$
(Position: $(50 + 1)/2 = 25.5$)

$$\bar{x} = \frac{1}{n} \sum x_i f_i = \frac{1}{50} (0 \cdot 8 + 1 \cdot 12 + 2 \cdot 18 + 3 \cdot 10 + 4 \cdot 2) = \frac{86}{50} = 1.72$$

$$\bar{x} = \sum x_i \left(\frac{f_i}{n} \right) = 0 \cdot \underbrace{0.16}_{16\%} + 1 \cdot 0.24 + 2 \cdot 0.36 + 3 \cdot 0.20 + 4 \cdot 0.04 = 1.72$$

Populationsvarianz bei gruppierten Daten

- Für eine **Population** der Grösse N ist die **Varianz** bei gruppierten Daten

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^k (x_i - \mu)^2 f_i = \frac{1}{N} \sum_{i=1}^k x_i^2 f_i - \mu^2$$

- Falls **relative Häufigkeiten** vorliegen, ergibt sich

$$\sigma^2 = \sum_{i=1}^k (x_i - \mu)^2 \left(\frac{f_i}{N} \right) = \sum_{i=1}^k x_i^2 \left(\frac{f_i}{N} \right) - \mu^2$$

$\mu = 2, x_1 = 1, x_2 = 1, x_3 = 1$

$$\sigma^2 = \frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2 = \frac{1}{10} \left(\underbrace{(1-2)^2 + (1-2)^2 + (1-2)^2}_{(1-2)^2 \cdot 3} + \dots \right)$$

Stichprobenvarianz bei gruppierten Daten

- Für eine **Stichprobe** von n Beobachtungen ist die **Stichprobenvarianz** bei gruppierten Daten


$$s^2 = \frac{1}{n-1} \sum_{i=1}^k (x_i - \bar{x})^2 f_i = \frac{1}{n-1} \left(\sum_{i=1}^k x_i^2 f_i - n\bar{x}^2 \right)$$

- Ein Beispiel folgt im nächsten Abschnitt (klassierte Daten).
- Falls **relative Häufigkeiten** vorliegen, verwendet man üblicherweise die Formel für die **Populationsvarianz** (da dann n meist nicht bekannt ist).

Bemerkung $\frac{f_i}{n-1}$ ist nicht die relative Häufigkeit, $\frac{f_i}{n-1} = \left(\frac{f_i}{n} \right) \frac{n}{n-1}$

5 Anrufe 10 An

Anrufe : $0 < 2, 2 < 4, 4 < 6, \dots$ (Minuten)



Approximationen bei klassierten Daten

- Angenommen die Daten sind in k Klassen eingeteilt mit absoluten Häufigkeiten f_1 bis f_k (bzw. relativen Häufigkeiten f_1/n bis f_k/n) und **Klassenmitten** m_1 bis m_k .
- Das **arithmetische Mittel bei klassierten Daten** ist *approximativ*:

$$\bar{x} \approx \frac{1}{n} \sum_{i=1}^k m_i f_i = \sum_{i=1}^k m_i \left(\frac{f_i}{n} \right)$$


- Gegenüber den Formeln zu den gruppierten Daten gibt es **zwei Anpassungen**:
 - Die tatsächlichen Werte (x_i) werden durch die Klassenmitten (m_i) ersetzt.
 - Man erhält lediglich eine Approximation ($\approx$) des Mittelwertes. Warum?
- **Die Formeln für die Varianz erhält man gleichermassen.**

Klassierte Daten: Beispiel

- SAT (Scholastic Aptitude Test) Verbal Scores, Zufallsstichprobe der Grösse $n = 427$
- Häufigkeitsverteilung:

SAT Verbal Score	f_i	f_i/n (in %)
200 < 300	10	2.34
300 < 400	40	9.37
400 < 500	142	33.26
500 < 600	172	40.28
600 < 700	63	14.75
	427	100.00

50%
↖



Quelle: Ramanathan, Introductory Econometrics with Applications

- Finden Sie die Modus- und Medianklasse.
- Schätzen Sie den arithmetischen Mittelwert und die Standardabweichung von SAT Verbal Scores.

$$\text{Rangzahl} = \frac{n+1}{2}$$

Klassierte Daten: Beispiel (Forts.)

- Modusklasse: 500 < 600 Punkte
- Medianklasse: 500 < 600 Punkte
- Schätzwerte von Mittelwert und Standardabweichung:




$$\bar{x} \approx \frac{\sum_{i=1}^K m_i f_i}{n} = \frac{250 \cdot 10 + 350 \cdot 40 + 450 \cdot 142 + 550 \cdot 172 + 650 \cdot 63}{427} = 505.7377$$



$$s \approx \sqrt{\frac{\sum_{i=1}^K m_i^2 f_i - n \bar{x}^2}{n-1}} = \sqrt{\frac{250^2 \cdot 10 + \dots + 650^2 \cdot 63 - 427 \cdot 505.7377^2}{427-1}} = 93.365$$

☞ Die exakten Statistiken (aus nicht klassierten Daten) sind: $M_o = M_e = 500$,
 $AM = 501.80$ und $s = 91.31$.

~~_____~~



x_i	y_i
1	5
.	.
.	.
.	.



§ 4 Kovarianz

- Die Kovarianz misst die Stärke des **linearen Zusammenhangs zwischen zwei Variablen**.
- Die Kovarianz in der Grundgesamtheit:

$$\text{Cov}(x, y) = \sigma_{xy} = \frac{\sum_{i=1}^N (x_i - \mu_x)(y_i - \mu_y)}{N} = \frac{\sum_{i=1}^N x_i y_i}{N} - \mu_x \mu_y$$

- Die Stichproben-Kovarianz:

$$\text{Cov}(x, y) = s_{xy} = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n-1} = \frac{\sum_{i=1}^n x_i y_i - n \bar{x} \bar{y}}{n-1}$$

☞ Achtung: Die Stärke eines (linearen) Zusammenhangs sagt nichts über die **Kausalität** aus!

Die Kovarianz interpretieren

Interpretation der Kovarianz zweier Variablen:

- $\text{Cov}(x,y) > 0$ → tendenziell bewegen sich x und y gleichläufig
- $\text{Cov}(x,y) < 0$ → tendenziell bewegen sich x und y gegenläufig
- $\text{Cov}(x,y) = 0$ → x und y sind *linear* unabhängig

Der Korrelationskoeffizient

- Die Kovarianz ist schwierig zu interpretieren.
- Der **Korrelationskoeffizient** (nach Bravais/Pearson) ist ein *standardisiertes Mass*, das sowohl die *Richtung als auch die Stärke* des linearen Zusammenhangs zweier Variablen misst.

- **Korrelationskoeffizient**

- Grundgesamtheit:

$$\rho = \frac{\text{Cov}(x,y)}{\sigma_x \sigma_y} = \frac{\sigma_{xy}}{\sigma_x \sigma_y}$$

- Stichprobe:



$$r = \frac{\text{Cov}(x,y)}{s_x s_y} = \frac{s_{xy}}{s_x s_y}$$

Merkmale des Korrelationskoeffizienten







- ρ (bzw. r) liegt immer zwischen -1 und 1 . (Die Kennzahl ist normiert und frei von Masseinheiten).

$$-1 \leq \rho \leq 1$$
- Je näher r bei 1 (-1) liegt, desto *stärker* ist der positive (negative) lineare Zusammenhang zwischen x und y .
- Je näher r bei 0 liegt, desto *schwächer* ist der lineare Zusammenhang zwischen x und y .
- Korrelation impliziert nicht Kausalität!







Streuungsdiagramme für verschiedene Korrelationskoeffizienten




Streuungsdiagramme für verschiedene Korrelationskoeffizienten (Forts.)



- Starker, *nicht linearer* Zusammenhang
- Erste und zweite Datenhälften «gleichen sich aus», so dass $r \approx 0$.




- x und y sind hoch korreliert.
- Der Zusammenhang ist dennoch nicht linear.



- Starker, nicht linearer Zusammenhang
- Segmente mit positiven und negativen Beziehungen «gleichen sich aus», so dass $r \approx 0$.

Korrelation: Beispiel

- Korrelation zwischen SAT (Scholastic Aptitude Test) Punkten im verbalen und mathematischen Teil ($n = 427$)
- Streudiagramm:



Quelle: Ramanathan, Introductory Econometrics with Applications

■ $r = 0.42$

- Der lineare Zusammenhang ist eher schwach bis mittelstark. Insb. die Punkte oben links im Streudiagramm reduzieren r . Wie könnte man diese Beobachtungen erklären?

Wahrscheinlich handelt es sich um Ausländer, die an einem US College studieren wollen (stark in Mathe, eher schwach im Englischen).

Kovarianz und Korrelation: Vereinfachtes Beispiel

- Die Berechnung von Korrelationen ist ohne Statistiksoftware zeitaufwändig.
- Zur Veranschaulichung wird daher eine Zufallsstichprobe der Grösse $n = 5$ aus den Originaldaten gezogen.
 - ☞ Das Beispiel dient lediglich didaktischen Zwecken. *Verwenden Sie in Ihren Untersuchungen keine so kleinen Stichproben!*
- Aus der ursprünglichen (grossen) Stichprobe wurde eine Zufallsstichprobe der Grösse $n = 5$ gezogen:

Verbal (x)	490	550	460	500	570
Math (y)	660	550	490	550	680

Kovarianz und Korrelation: Vereinfachtes Beispiel (Forts.)

- Daten:

Verbal (x)	490	550	460	500	570
Math (y)	660	550	490	550	680

- Statistiken (verifizieren Sie die Resultate zu Hause!):

$$\bar{x} = 514, \quad \bar{y} = 586, \quad s_x = 45.056, \quad s_y = 80.808$$


- $$s_{xy} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n - 1}$$

Die Berechnung mit der Alternativformel wäre schneller, aber weniger intuitiv!

$$\begin{aligned} &= \frac{(490 - 514)(660 - 586) + \dots + (570 - 514)(680 - 586)}{5 - 1} \\ &= \frac{-1776 - 1296 + 5184 + 504 + 5264}{4} = \frac{7880}{4} = 1970 \end{aligned}$$

Kovarianz und Korrelation: Vereinfachtes Beispiel (Forts.)

- SAT verbal score versus SAT math score: Graphische Analyse



Kovarianz und Korrelation: Vereinfachtes Beispiel (Forts.)

- Gegeben: $s_x = 45.056$, $s_y = 80.808$, $s_{xy} = 1970$
- Korrelationskoeffizient:

$$r = \frac{\boxed{\text{Cov}}(x,y)}{s_x s_y} = \frac{s_{xy}}{s_x s_y} = \frac{1970}{45.056 \cdot 80.808} = 0.541$$

- Feststellung: Der Wert von r hat sich gegenüber der ursprünglichen (grossen) Stichprobe verändert.
- Obiger Korrelationskoeffizient sollte nicht interpretiert werden, da die Stichprobe viel zu klein ist.
- Bei grösserer Stichprobe ($n > 10$) erweist sich folgende **Faustregel** als nützlich: Von einem linearen Zusammenhang (in der Grundgesamtheit) kann ausgegangen werden, falls

$$\boxed{|r| \geq \frac{2}{\sqrt{n}}}$$