



School of
Management and Law

Statistik (w.BA.XX.2Stat-WIN.XX)

Teil 5: Stetige Zufallsvariablen und Wahrscheinlichkeitsverteilungen

Newbold, Carlson, Thorne: Statistics for Business and Economics, 8. Auflage
Kapitel 5: Stetige Zufallsvariablen und Wahrscheinlichkeitsverteilungen (5.1 – 5.4)



Building Competence. Crossing Borders.

Copyright © 2013 Pearson Education, Inc. Publishing as Prentice Hall.


Verantwortlich martin.schnauss@zhaw.ch

Lernziele:

Nach Bearbeitung dieses Teils können Sie:

- den Unterschied zwischen diskreten und stetigen Zufallsvariablen erklären.
- die Charakteristiken der Uniform- und Normalverteilung beschreiben.
- Wahrscheinlichkeiten einer normalverteilten Zufallsvariable durch Standardisierung und Wahrscheinlichkeitstabellen finden.
- beurteilen, ob Daten (approximativ) normalverteilt sind.
- die Normalapproximation der Binomialverteilung einsetzen.

Wahrscheinlichkeitsverteilungen



§ 1 Stetige Wahrscheinlichkeitsverteilungen

- Eine **stetige Zufallsvariable** ist eine Variable, welche jeden Wert in einem Intervall annehmen kann; z.B.:
 - Gewicht eines Gegenstandes
 - Zeitaufwand für eine bestimmte Arbeit
 - Temperatur eines Kühlaggregates
 - Körpergrösse
- Diese Grössen können theoretisch jeden Wert annehmen. Messungen führen aber zu *gerundeten* Ergebnissen.

Verteilungs- und Dichtefunktion


- Die **Verteilungsfunktion** $F(x_0)$ für eine Zufallsvariable X gibt die Wahrscheinlichkeit, dass X höchstens den Wert x_0 annimmt.
- Bei diskreten Zufallsvariablen haben wir die kumulierte Wahrscheinlichkeit durch eine *Summe* ermittelt. Bei stetigen Zufallsvariablen tritt an die Stelle der Summe ein **Integral**:

$$F(x_0) = P(X \leq x_0) = \int_{-\infty}^{x_0} f(x) dx$$

- **$f(x)$ nennt man die Dichtefunktion.** Sie ist das theoretische Pendant zur Häufigkeitsdichte («Höhe») des Histogramms.

Dichtefunktion und Verteilungsfunktion (Forts.)

Die (kumulative) **Verteilungsfunktion** $F(x_0)$ gibt die Fläche unter der **Dichtefunktion** $f(x)$ von minus unendlich (bzw. vom kleinsten Wert) bis zu x_0 .



Dichtefunktion


Die **Dichtefunktion** $f(x)$ einer stetigen Zufallsvariable X hat die folgenden Eigenschaften:

1. $f(x) \geq 0$ für alle möglichen Werte von x .
2. Die Fläche unter der Dichtefunktion $f(x)$ über alle möglichen Werte der Zufallsvariable X ist gleich 1.
3. Die Wahrscheinlichkeit, dass X zwischen zwei Werten a und b liegt, entspricht der Fläche unter der Dichtefunktion zwischen diesen zwei Werten.

Wahrscheinlichkeit als Fläche unter der Dichtefunktion

- Die **schraffierte Fläche unter der Dichtefunktion** entspricht der Wahrscheinlichkeit, dass X zwischen a und b ist.

$$P(a \leq X \leq b) = P(a < X < b) = \int_a^b f(x) dx$$




Hinweis: Die WK eines bestimmten Wertes ist 0 bei stetigen Zufallsvariablen!

Wahrscheinlichkeit als Fläche unter der Dichtefunktion (Forts.)

- Die gesuchte Fläche = Wahrscheinlichkeit erhalten wir wie folgt aus der Verteilungsfunktion:


$$P(a \leq X \leq b) = F(b) - F(a)$$



Die stetige Uniformverteilung

(auch stetige Gleichverteilung oder Rechteckverteilung)

- Die **Uniformverteilung** ist eine Wahrscheinlichkeitsverteilung mit **identischer Dichte** für alle möglichen Ausprägungen der Zufallsvariable.



- Beispiel einer uniformverteilten Zufallsvariable: Mechanische Uhr, die (gleich) zufällig im Intervall $(0, 12]$ (Uhr) stehen bleibt.

Die stetige Uniformverteilung (Forts.)

- Dichtefunktion der stetigen Uniformverteilung:

$$f(x) = \begin{cases} \frac{1}{b-a} & \text{falls } a \leq x \leq b \\ 0 & \text{sonst} \end{cases}$$

wobei



- $f(x)$ = Funktionswert der Dichtefunktion
 - a = minimaler Wert der Zufallsvariable X
 - b = maximaler Wert der Zufallsvariable X
- Erwartungswert und Varianz der stetigen Uniformverteilung:

$$\mu = E(X) = \frac{a+b}{2}$$

$$\sigma^2 = \text{Var}(X) = \frac{(b-a)^2}{12}$$

Die stetige Uniformverteilung: Die Verteilungsfunktion

- Dichte- versus Verteilungsfunktion:



Beispiel zur stetigen Uniformverteilung


Die Zufallsvariable X sei uniformverteilt im Intervall $2 \leq x \leq 6$. Gesucht:

a) Dichtefunktion $f(x)$; b) Erwartungswert und Varianz; c) $P(2.5 \leq X \leq 4)$

a) Dichtefunktion: $f(x) = \frac{1}{b-a} = \frac{1}{6-2} = 0.25$ für $2 \leq x \leq 6$; 0 ansonsten

b) Erwartungswert: $\mu = \frac{a+b}{2} = \frac{2+6}{2} = 4$; Varianz: $\sigma^2 = \frac{(b-a)^2}{12} = \frac{(6-2)^2}{12} = 1.33$

c) $P(2.5 \leq X \leq 4) = (4 - 2.5) \cdot 0.25 = 0.375$



Evt. hier Lösung mit Verteilungsfunktion.

§ 2 Erwartungswert und Varianz einer stetigen Zufallsvariable

- Erwartungswert und Varianz werden bei diskreten Zufallsvariablen durch Summen ermittelt. Bei stetigen Zufallsvariablen werden die Kennzahlen durch Integration ermittelt.
- **Erwartungswert** der Zufallsvariable X :

$$\mu_X = E(X) = \int_{-\infty}^{\infty} xf(x)dx$$

- **Varianz** der Zufallsvariable X :

$$\sigma_X^2 = Var(X) = E[(X - \mu_X)^2] = \int_{-\infty}^{\infty} (x - \mu_X)^2 f(x)dx$$

Lineare Transformationen von Zufallsvariablen

- Wir haben bereits im 4. Kapitel lineare Transformationen von Zufallsvariablen besprochen. Zur Erinnerung:
- X sei eine Zufallsvariable mit Erwartungswert μ_X und Varianz σ_X^2 .
- a und b seien zwei beliebige Konstanten.
- Somit gilt:

$$E(a + bX) = a + b\mu_X$$

$$Var(a + bX) = b^2 Var(X) = b^2 \sigma_X^2$$

Standardisierte Zufallsvariable

- Ein wichtiger Spezialfall der soeben repetierten Transformation ist die **standardisierte Zufallsvariable**:

$$Z = \frac{X - \mu_X}{\sigma_X}$$

- Die standardisierte Zufallsvariable Z hat einen **Erwartungswert von 0** und eine **Varianz von 1**. Beweis:


$$E(Z) = E\left(\frac{X - \mu_X}{\sigma_X}\right) = \frac{1}{\sigma_X} E(X - \mu_X) = \frac{1}{\sigma_X} [E(X) - E(\mu)] = 0$$

$$Var(Z) = Var\left(\frac{X - \mu_X}{\sigma_X}\right) = \frac{1}{\sigma_X^2} Var(X - \mu_X) = \frac{1}{\sigma_X^2} Var(X) = 1$$

§ 3 Die Normalverteilung

Charakteristik der Normalverteilung:

- **Form: Glockenförmig symmetrisch**
 - Somit: Erwartungswert = Median = Modus
- **Lage der Verteilung:** Wird durch den Erwartungswert μ bestimmt.
- **Streuung der Verteilung:** Wird durch die Standardabweichung σ bestimmt.
- **Definitionsbereich:** Die Zufallsvariable X kann jeden beliebigen reellen Wert annehmen (von $-\infty$ bis $+\infty$).




Die Normalverteilung (Forts.)

Die Normalverteilung ist die wichtigste (stetige) Wahrscheinlichkeitsverteilung. Gründe dafür sind:

- Die Normalverteilung approximiert eine Vielzahl von Zufallsvariablen, wie Abfüllgewichte, Schwangerschaftsdauer, Intelligenzquotienten, Schuhgrößen, Wertpapierrenditen (mit Vorbehalt)
- Einige Stichprobenstatistiken (z.B. arithmetisches Mittel) sind approximativ normalverteilt für grosse Stichproben.
- Einfache mathematische Handhabung

Gestalt der Normalverteilung




Wir führen folgende verbreitete Notation ein, um eine normalverteilte Zufallsvariable X mit Erwartungswert μ und Varianz σ^2 zu definieren:

$$X \sim N(\mu, \sigma^2)$$

Gestalt der Normalverteilung (Forts.)

Durch Variierung der Parameter μ und σ können verschiedene Normalverteilungen erzeugt werden:



Die Dichtefunktion der Normalverteilung

Die **Dichtefunktion einer Normalverteilung** lautet:

$$f(x) = \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2}$$

wobei e = Eulersche Konstante (2.71828...)

π = Kreiszahl (3.14159...)

μ = Erwartungswert bzw. Mittelwert der Verteilung

σ = Standardabweichung der Verteilung


x = reelle Zahl, $-\infty < x < \infty$

Die Verteilungsfunktion der Normalverteilung

Die (kumulative) **Verteilungsfunktion** der Normalverteilung ist

$$F(x_0) = P(X \leq x_0) = \int_{-\infty}^{x_0} f(x) dx = \int_{-\infty}^{x_0} \frac{1}{\sqrt{2\pi\sigma^2}} e^{-\frac{1}{2}\left(\frac{x-\mu}{\sigma}\right)^2} dx$$

☞ Die Funktion ist nicht geschlossen integrierbar. Wir werden Flächen bzw. Wahrscheinlichkeiten mit Tabellen oder elektronischen Hilfsmitteln (TR, Python, Excel, ...) bestimmen.




Symmetrie der Normalverteilung

- Die Gesamtfläche unter einer Dichtefunktion ist 1, wobei Flächen Wahrscheinlichkeiten repräsentieren.

$$P(-\infty < X < \infty) = 1$$


- Da die Verteilung symmetrisch ist, **entspricht der Erwartungswert dem Median**. Der Erwartungswert teilt die Gesamtfläche in zwei gleich grosse Teile (je eine Fläche von 0.5).



Die Standardnormalverteilung

- Jede normalverteilte Zufallsvariable X (mit beliebigem μ_X und σ_X^2) kann in eine **standardnormalverteilte Zufallsvariable Z** mit $\mu_Z = 0$ und $\sigma_Z^2 = 1$ transformiert werden.

$$Z \sim N(0,1)$$



- Ist X eine normalverteilte Zufallsvariable mit Mittelwert μ und Standardabweichung σ , so erhält man eine standardnormalverteilte Zufallsvariable Z durch folgende Transformation:

$$Z = \frac{X - \mu}{\sigma}$$

Beispiel zur Standardisierung

- Falls X normalverteilt ist mit Erwartungswert 8 und Varianz 4, dann ist der z -Wert für $x = 10$.


$$z = \frac{(x - \mu)}{\sigma} = \frac{10 - 8}{2} = 1$$

- $x = 10$ ist somit eine Standardabweichungen (1-mal 2 Einheiten) über dem Erwartungswert von 8.

Beispiel zur Standardisierung (Forts.)

- Die Standardisierung ändert im Prinzip lediglich die Skalierung der Normalverteilung. Es gilt in unserem Beispiel ($X \sim N(8,4)$):

$$P(X \leq 10) = P\left(Z \leq \frac{10 - 8}{2}\right) = P(Z \leq 1)$$



Ermittlung von Wahrscheinlichkeiten durch Standardisierung

- Allgemein gilt für eine normalverteilte Zufallsvariable X mit Erwartungswert μ und Varianz σ^2 :

$$F_X(x_0) = P(X \leq x_0) = P\left(Z \leq \frac{x_0 - \mu}{\sigma}\right) = F_Z\left(\frac{x_0 - \mu}{\sigma}\right)$$

- $F_X(x)$ ist hierbei die Verteilungsfunktion der normalverteilten Zufallsvariable X und $F_Z(z)$ jene der standardnormalverteilten Zufallsvariable Z .
- **Problemstellungen für X können somit in solche für Z überführt werden. Für letztere gibt es Wahrscheinlichkeitstabellen.**

Benutzung der Wahrscheinlichkeitstabelle

- Die Wahrscheinlichkeitstabelle A-1 im Übungsband stellt die Verteilungsfunktion der Standardnormalverteilung tabellarisch dar.

- Mit der Tabelle erhält man für einen bestimmten Wert z_1 den Funktionswert


$$F(z_1) = P(Z \leq z_1)$$

welcher der Fläche unter der Dichtefunktion von minus unendlich bis a entspricht.

- Beispiel:

$$P(Z \leq 0.95) = F(0.95) = 0.8289$$

Tab. A-1: Verteilungsfunktion der Standardnormalverteilung $F(z)$ ^a





z	0	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389

Benutzung der Wahrscheinlichkeitstabelle (Forts.)

- Durch elementare mathematische/geometrische Überlegungen lösen wir weitere Probleme mit der Wahrscheinlichkeitstabelle:




$$\begin{aligned}P(Z > 0.95) &= 1 - P(Z \leq 0.95) \\&= 1 - F(0.95) \\&= 1 - 0.8289 \\&= 0.1711\end{aligned}$$

$$\begin{aligned}P(Z < -0.95) &= P(Z > 0.95) \\&= 0.1711\end{aligned}$$




Benutzung der Wahrscheinlichkeitstabelle (Forts.)

- Gesucht $P(-0.52 < Z < 0.95)$



Tab. A-1: Verteilungsfunktion der Standardnormalverteilung $F(z)$ ^a



z	0	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389

$$P(-0.52 < Z < 0.95)$$

$$= P(Z < 0.95) - P(Z < -0.52)$$

$$= F(0.95) - F(-0.52)$$


$$= 0.8289 - (1 - 0.6985) = 0.5274$$

Grundsätzliches Vorgehen

- Gegeben: $X \sim N(\mu, \sigma^2)$
- Gesucht: $P(a < X < b)$, wobei $b > a$
- Grundsätzliches Vorgehen zur Lösung des Problems:
 - 1) Skizze der Normalverteilung für das Problem bezüglich X
 - 2) x -Werte in z -Werte transformieren
 - 3) Tabelle der Verteilungsfunktion benutzen


Grundsätzliches Vorgehen (Forts.)

- Es sei $X \sim N(\mu, \sigma^2)$ und $Z \sim N(0,1)$ mit Verteilungsfunktion $F(z)$.
- Gesucht ist $P(a \leq X \leq b)$.



Berechnung von Wahrscheinlichkeiten: Beispiel



- IQ-Tests sind so kalibriert, dass der mittlere Intelligenzquotient 100 und die Standardabweichung 15 Punkte beträgt.
- Die Zufallsvariable X sei der IQ einer zufällig getesteten Person.
- Es gilt somit: $X \sim N(100, 225)$
- Mit welcher Wahrscheinlichkeit liegt X zwischen 90 und 120?



Berechnung von Wahrscheinlichkeiten: Beispiel (Forts.)

- Es gilt: $X \sim N(100, 225)$
- Somit:


$$P(90 < X < 120) = P\left(\frac{90 - 100}{15} < Z < \frac{120 - 100}{15}\right) \cong P(-0.67 < Z < 1.33)$$




Berechnung von Wahrscheinlichkeiten: Beispiel (Forts.)

- Es gilt: $X \sim N(100, 225)$. Somit:

$$\begin{aligned}
 &P(-0.67 < Z < 1.33) \\
 &= F(1.33) - F(-0.67) \\
 &= F(1.33) - (1 - F(0.67)) \\
 &= 0.9082 - (1 - 0.7486) = 0.6568 \\
 &= 65.68\%
 \end{aligned}$$



Tab. A-1: Verteilungsfunktion der Standardnormalverteilung $F(z)$ ^a



z	0	0.01	0.02	0.03	0.04	0.05	0.06	0.07	0.08	0.09
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279	0.5319	0.5359
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675	0.5714	0.5753
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064	0.6103	0.6141
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443	0.6480	0.6517
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808	0.6844	0.6879
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157	0.7190	0.7224
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486	0.7517	0.7549
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794	0.7823	0.7852
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8078	0.8106	0.8133
0.9	0.8159	0.8186	0.8212	0.8238	0.8264	0.8289	0.8315	0.8340	0.8365	0.8389
1.0	0.8413	0.8438	0.8461	0.8485	0.8508	0.8531	0.8554	0.8577	0.8599	0.8621
1.1	0.8643	0.8665	0.8686	0.8708	0.8729	0.8749	0.8770	0.8790	0.8810	0.8830
1.2	0.8849	0.8869	0.8888	0.8907	0.8925	0.8944	0.8962	0.8980	0.8997	0.9015
1.3	0.9032	0.9049	0.9066	0.9082	0.9099	0.9115	0.9131	0.9147	0.9162	0.9177
1.4	0.9192	0.9207	0.9222	0.9236	0.9251	0.9265	0.9279	0.9292	0.9306	0.9319

Wahrscheinlichkeit gegeben, Quantil gesucht

In der Statistik ist die zweite Anwendung, nämlich aus einer bestimmten Wahrscheinlichkeit den entsprechenden Quantilswert zu finden, mindestens so wichtig. Beispiele hierfür sind:

- Intervallschätzung (siehe insb. Kapitel 7)
- Risikomanagement (insb. parametrischer Value at Risk)


Schritte, um aus einer gegebenen Wahrscheinlichkeit den entsprechenden x -Wert (Quantil) zu finden:

1. Bestimmung des z -Wertes (z -Quantil) für die gegebene Wahrscheinlichkeit
2. z -Quantil in x -Quantil transformieren mittels:

$$z = \frac{x - \mu}{\sigma} \quad \Leftrightarrow \quad x = \mu + z\sigma$$

Wahrscheinlichkeit gegeben, Quantil gesucht: Beispiel


- X sei normalverteilt mit $\mu = 100$ und $\sigma = 15$ (entspricht der IQ-Verteilung)
- Man bestimme denjenigen x -Wert (IQ), so dass $P(X < x) = 20\%$.
- Mit anderen Worten suchen wir das 20%-Quantil der (IQ-) Verteilung.
(hier gebrauchte Notation für das 20%-Quantil: $x_{0.2}$)




1. Schritt: Bestimmung des z -Quantils

- 20% der Fläche liegt unterhalb welchem z -Wert? Gesucht ist also $z_{0.2}$ in

$$F(z_{0.2}) = 0.2$$
- Die Tabelle belegt, dass $z_{0.8} \cong 0.84$
- Aus Symmetriegründen: $z_{0.2} \cong -0.84$



Tab. A-1: Verteilungsfunktion der Standardnormalverteilung $F(z)$ ^a



z	0	0.01	0.02	0.03	0.04	0.05	0.06	0.07
0.0	0.5000	0.5040	0.5080	0.5120	0.5160	0.5199	0.5239	0.5279
0.1	0.5398	0.5438	0.5478	0.5517	0.5557	0.5596	0.5636	0.5675
0.2	0.5793	0.5832	0.5871	0.5910	0.5948	0.5987	0.6026	0.6064
0.3	0.6179	0.6217	0.6255	0.6293	0.6331	0.6368	0.6406	0.6443
0.4	0.6554	0.6591	0.6628	0.6664	0.6700	0.6736	0.6772	0.6808
0.5	0.6915	0.6950	0.6985	0.7019	0.7054	0.7088	0.7123	0.7157
0.6	0.7257	0.7291	0.7324	0.7357	0.7389	0.7422	0.7454	0.7486
0.7	0.7580	0.7611	0.7642	0.7673	0.7704	0.7734	0.7764	0.7794
0.8	0.7881	0.7910	0.7939	0.7967	0.7995	0.8023	0.8051	0.8079

Hinweis: Wir interpolieren nicht sondern nehmen einfach den passendsten Wert.

2. Schritt: Von z nach x transferieren

- Der Quantilswert der Standardnormalverteilung muss nun noch in die Normalverteilung für X überführt werden.

$$x = \mu + z\sigma$$

- Somit:

$$x_{0.2} \cong 100 + (-0.84) \cdot 15 = 100 - 0.84 \cdot 15 = 87.4$$

- Fazit:
 - Ca. 20% der Werte in einer Normalverteilung mit Erwartungswert 100 und Varianz 225 liegen unter 87.4.
 - Es gilt also $P(X < 87.4) \cong 20\%$, falls $X \sim N(100, 225)$
 - Ca. 20% der Menschen hat einen IQ von höchstens 87 Punkten, falls $\mu = 100$ und $\sigma^2 = 225$.

Von Daten zum Modell

- Theoretische Verteilungen werden oft gebraucht, um empirische Daten kompakt zu beschreiben bzw. zu modellieren. Wir haben dies zuvor bereits im Beispiel der Intelligenzquotienten implizit gemacht.
- In der Finance werden empirische Renditeverteilungen oft durch theoretische Verteilungen beschrieben (z.B. Risikomanagement, Portfoliotheorie, Optionspreisbestimmung).
- Oft (aber nicht immer!) eignet sich die Normalverteilung, empirische Daten zu beschreiben.
- Wie können wir feststellen, ob Daten approximativ normalverteilt sind?

Sind die Daten normalverteilt?

- Offensichtlich ist nicht jedes Merkmal normalverteilt.
- Es ist daher wichtig zu untersuchen, *wie gut die Daten durch eine Normalverteilung approximiert* werden können.
- Verschiedene Methoden werden dazu eingesetzt:
 - **Histogramm** (mit überlagerter theoretischer Normalverteilung)
 - **Numerische Zusammenfassung** (Statistiken) der Verteilung
 - Der Median sollte etwa dem arithmetischen Mittelwert entsprechen.
 - Die Schiefe und Überwölbung sollte nahe 0 liegen.
 - (Die empirischen Perzentile sollten den theoretischen entsprechen. Einfacher geht das mit dem Q-Q-Plot)
 - **Q-Q-Plot**
 - Das Quantil-Quantil-Diagramm ist ein sehr gutes Diagramm, um empirische mit theoretischen Verteilungen zu vergleichen.
 - **Anpassungstests** (goodness-of-fit tests)
 - Werden hier nicht näher erläutert.

Von Daten zum Modell


Das Prinzip/Vorgehen soll an einem Beispiel erläutert werden. Hierzu dient die Punkteverteilung einer fiktiven Modulendprüfung mit 60pt.

The FREQ Procedure

Punkte				
Punkte	Frequency	Percent	Cumulative Frequency	Cumulative Percent
0 - 5 Punkte	11	3.67	11	3.67
6 - 10 Punkte	5	1.67	16	5.33
11 - 15 Punkte	19	6.33	35	11.67
16 - 20 Punkte	36	12.00	71	23.67
21 - 25 Punkte	39	13.00	110	36.67
26 - 30 Punkte	43	14.33	153	51.00
31 - 35 Punkte	54	18.00	207	69.00
36 - 40 Punkte	36	12.00	243	81.00
41 - 45 Punkte	19	6.33	262	87.33
45+ Punkte	38	12.67	300	100.00

Von Daten zum Modell (Forts.)

- Die Punkteverteilung scheint *approximativ* normalverteilt zu sein.
- Die grundlegenden Statistiken widersprechen diesem Befund nicht.



The UNIVARIATE Procedure
Variable: Punkte (Punkte)

Moments			
N	300	Sum Weights	300
Mean	28.96	Sum Observations	8688
Std Deviation	12.6379373	Variance	159.717458
Skewness	0.13157909	Kurtosis	-0.1846076
Uncorrected SS	299360	Corrected SS	47755.52
Coeff Variation	43.6392861	Std Error Mean	0.72965165

Basic Statistical Measures			
Location		Variability	
Mean	28.96000	Std Deviation	12.63794
Median	29.00000	Variance	159.71746
Mode	30.00000	Range	58.00000
		Interquartile Range	17.00000


Tests for Location: Mu0=0			
Test	Statistic	p Value	
Student's t	t 39.69017	Pr > t	<.0001
Sign	M 150	Pr >= M	<.0001
Signed Rank	S 22575	Pr >= S	<.0001

Quantiles (Definition 5)	
Level	Quantile
100% Max	59.0
99%	58.5
95%	52.5
90%	45.5
75% Q3	37.0
50% Median	29.0
25% Q1	20.0
10%	13.0
5%	8.5
1%	1.0
0% Min	1.0

Extreme Observations			
Lowest		Highest	
Value	Obs	Value	Obs
1	6	58	296
1	5	58	297
1	4	59	298
1	3	59	299
1	2	59	300

Von Daten zum Modell (Forts.)

- Der **Q-Q-Plot** (Quantil-Quantil-Diagramm) ist dafür geschaffen, empirische mit theoretischen Verteilungen (hier Normalverteilung) zu vergleichen.
- Falls die beobachteten (empirischen) Quantile nahe an den theoretischen Quantilen (hier einer Normalverteilung mit gleichem Mittelwert und Varianz wie die zugrundeliegenden Daten) sind, liegen die (roten) Punkte auf der «Hilfsgeraden» ($y = x$).
- Dies ist hier der Fall: *Die Daten sind somit approximativ normalverteilt.*




Von Daten zum Modell (Forts.)

- Modellierung der Daten durch eine Normalverteilung mit gleichem Mittelwert und Varianz.


Modell: $X \sim N(28.96, 12.6379^2)$

Moments			
N	300	Sum Weights	300
Mean	28.96	Sum Observations	8688
Std Deviation	12.6379373	Variance	159.717458
Skewness	0.13157909	Kurtosis	-0.1846076
Uncorrected SS	299360	Corrected SS	47755.52
Coeff Variation	43.6392861	Std Error Mean	0.72965165



Von Daten zum Modell (Forts.)

- Welcher Anteil der Studierenden hat *laut der empirischen Verteilung* (Häufigkeitsverteilung) höchstens 30 Punkte erreicht?
- Welcher Anteil der Studierenden hat *laut dem Modell* (Normalverteilung) höchstens 30 Punkte erreicht?




- Die Fläche unter der Häufigkeitsdichte (Histogramm) links von 30 Punkten ergibt die Lösung mittels empirischer Verteilung.
- Die Fläche unter der Dichte der Normalverteilung links von 30 Punkten ergibt die Lösung mittels Modell.

Von Daten zum Modell (Forts.)

Lösung mittels Häufigkeitsverteilung:

The FREQ Procedure


Punkte				
Punkte	Frequency	Percent	Cumulative Frequency	Cumulative Percent
0 - 5 Punkte	11	3.67	11	3.67
6 - 10 Punkte	5	1.67	16	5.33
11 - 15 Punkte	19	6.33	35	11.67
16 - 20 Punkte	36	12.00	71	23.67
21 - 25 Punkte	39	13.00	110	36.67
26 - 30 Punkte	43	14.33	153	51.00
31 - 35 Punkte	54	18.00	207	69.00
36 - 40 Punkte	36	12.00	243	81.00
41 - 45 Punkte	19	6.33	262	87.33
46+ Punkte	38	12.67	300	100.00



Lösung mittels Normalverteilung (Modell):

$$X \sim N(28.96, 12.6379^2)$$

$$\begin{aligned}
 P(X \leq 30) &= P\left(Z \leq \frac{30 - 28.96}{12.6379}\right) \\
 &\cong P(Z \leq 0.08) \\
 &\cong 0.53 = 53\%
 \end{aligned}$$



§ 4 Normalapproximation der Binomialverteilung

- Wie im 4. Kapitel gezeigt kann die binomialverteilte Zufallsvariable X als Summe von n *unabhängigen* Bernoulli-Zufallsvariablen geschrieben werden:

$$X = X_1 + X_2 + \cdots + X_n$$


wobei

- $x_i = 1$, falls der i -te Versuche ein «Erfolg» ist und $x_i = 0$, falls es sich um einen «Misserfolg» handelt
- mit entsprechenden Wahrscheinlichkeiten von p und $1 - p$
- und Erwartungswert und Varianz

$$\begin{aligned}\mu &= E(X) = np \\ \sigma^2 &= Var(X) = np(1 - p)\end{aligned}$$

Normalapproximation der Binomialverteilung (Forts.)

- Für grosse n kann die Binomialverteilung durch die Normalverteilung approximiert werden.
 - Illustration mit Erfolgswahrscheinlichkeit $p = 0.4$ in Abhängigkeit von n :



- Siehe Aufgabensammlung für eine weitere Illustration

Normalapproximation der Binomialverteilung (Forts.)

Wie gross muss n sein, damit die Normalapproximation «gut» ist?

- Die Antwort hängt von der Erfolgswahrscheinlichkeit p ab. Je weiter p von 0.5 weg ist, desto grösser muss n sein (um die Schiefe zu eliminieren).
- **Faustregel:**
 - Die Annäherung der Binomialverteilung durch die Normalverteilung ist «gut», falls $\sigma^2 = np(1 - p) > 5$
 - In diesem Fall ist die binomialverteilte Zufallsvariable X approximativ normalverteilt mit Erwartungswert $\mu = np$ und Varianz $\sigma^2 = np(1 - p)$.
 - Ein Beispiel hilft so oft ...

Normalapproximation der Binomialverteilung: Beispiel

40% aller Wähler (in einem grossen Land) unterstützen die Vorlage A. Wie hoch ist die Wahrscheinlichkeit, dass in einer Zufallsstichprobe der Grösse $n = 200$ höchstens 64 Wähler für A stimmen?

1. Berechnung von Erwartungswert und Varianz:

$$\mu = np = 200 \cdot 0.4 = 80$$

$$\sigma^2 = np(1 - p) = \mu(1 - p) = 80 \cdot (1 - 0.4) = 48$$

2. Faustregel überprüfen: σ^2 ist weit über 5, somit wird die Approximation sehr gut.

3. Berechnung der Wahrscheinlichkeit durch Normalapproximation:

$$P(X \leq 64) \approx P\left(Z \leq \frac{64 - 80}{\sqrt{48}}\right) = P(Z \leq -2.31) = 0.0104 \doteq 0.01$$

Hinweis: Die exakte Lösung mit Binomialverteilung ist: $P(X \leq 64) = 0.0119$.

Exkurs: Stetigkeitskorrektur bei der Normalapproximation

Bei der Normalapproximation der Binomialverteilung wird eine *diskrete* Zufallsvariable durch eine *stetige* approximiert.

- Man kann daher die Wahrscheinlichkeiten präziser approximieren, wenn eine sogenannte «Stetigkeitskorrektur» vorgenommen wird.
- Beispiel: Die Wahrscheinlichkeit, 64 Wähler für A in der Stichprobe zu haben, sollte eigentlich mit der Normalapproximation wie folgt berechnet werden:

$$P\left(\frac{63.5 - 80}{\sqrt{48}} \leq Z \leq \frac{64.5 - 80}{\sqrt{48}}\right)$$

Offensichtlich falsch wäre $P\left(Z = \frac{64 - 80}{\sqrt{48}}\right) = 0$.

- Folgerichtig wäre somit:

$$P(X \leq 64) \approx P\left(Z \leq \frac{64.5 - 80}{\sqrt{48}}\right) = 0.0126$$