



School of  
Management and Law

Statistik (w.BA.XX.2Stat-WIN.XX)

## Teil 9: Lineare Einfachregression

Newbold, Carlson, Thorne: Statistics for Business and Economics, 8. Auflage  
Kapitel 11: Lineare Einfachregression (Abschnitt 11.1-11.5)



Building Competence. Crossing Borders.

Copyright © 2013 Pearson Education, Inc. Publishing as Prentice Hall.

Verantwortlich [martin.schnauss@zhaw.ch](mailto:martin.schnauss@zhaw.ch)

# Lernziele:

## Nach Bearbeitung dieses Teils können Sie:

- den Zweck der Regressionsanalyse verstehen.
- den Unterschied zwischen einer Populationsregressionsfunktion und einer Stichprobenregressionsfunktion beschreiben.
- die Bedeutung der Regressionsannahmen erkennen.
- die Parameter einer Einfachregression schätzen und interpretieren.
- mittels einer Regressionsgleichung Prognosen (Punktschätzer) bilden.
- $R^2$  als ein Mass für die Güte des linearen Zusammenhangs berechnen und interpretieren.
- Konfidenzintervalle für die Regressionskoeffizienten berechnen und interpretieren.
- Hypothesen bezüglich der Regressionskoeffizienten testen.


# § 1 Einführung in die Regressionsanalyse

- Die **Regressionsanalyse** dient dazu,
  - auf der Grundlage von Werten mindestens einer unabhängigen Variable den Wert einer abhängigen Variable zu prognostizieren
  - die Auswirkung der Veränderung einer unabhängigen Variable auf die abhängige Variable zu erklären.
- **Zu erklärende Grösse:** abhängige Variable, endogene Variable, Regressand, Zielgrösse
- **Erklärende Grösse(n):** unabhängige Variable(n), exogene Variable(n), Regressor(en), Eingangsgrösse(n)

# Populationsregressionsfunktion


- Die Regressionsanalyse untersucht Beziehungen zwischen Variablen.
- Für die Einfachregression (lediglich eine unabhängige Variable) kann das Modell folgendermassen formuliert werden:
  - $E(Y|x) = f(x)$
  - Die Funktion wird **Populationsregressionsfunktion (PRF)** genannt.
- In vielen Fällen können wir den Zusammenhang durch eine **lineare Funktion** beschreiben/approximieren:
  - $E(Y|x) = \beta_0 + \beta_1 x$
  - Die Funktion wird **lineare Populationsregressionsfunktion** genannt.
  - $Y$  ist die abhängige (stochastische) Variable,  $x$  die unabhängige Variable,  $\beta_0$  der Ordinatenabschnitt und  $\beta_1$  die Steigung der linearen Funktion.

# Populationsregressionsfunktion (Forts.)



# Stochastische Spezifikation der PRF

- Darstellung der Abweichung von  $Y_i$  vom bedingten Erwartungswert
  - Störterm:  $\epsilon_i = Y_i - E(Y|x_i)$   
-> Umformen:  $Y_i = E(Y|x_i) + \epsilon_i$
- Falls  $E(Y|x_i)$  linear ist, erhalten wir das **Populationsregressionsmodell:**





# Modellannahmen

Die folgenden Annahmen sind nötig, um von Stichprobenergebnissen auf Populationsgrößen schliessen zu können (Inferenz):

1. Linearität: Das Modell kann wie folgt geschrieben werden:


$$Y_i = \beta_0 + \beta_1 x_i + \epsilon_i$$



➤ Hinweis: Das Modell muss eigentlich lediglich in den *Parametern* linear sein und nicht in den Variablen.

# Modellannahmen (Forts.)

## 2. Die Störterme, $\varepsilon_i$ , sind unabhängig von den $x$ -Werten.





Beispiel: Zusammenhang zwischen Schulbildung und Löhnen kann überschätzt werden, wenn (die nicht berücksichtigte) Intelligenz positiv mit der Schulbildung korreliert.

# Modellannahmen (Forts.)

## 3. Die Störterme sind Zufallsvariablen mit Erwartungswert 0 und konstanter Varianz.

- Die erste Annahme ( $E(\epsilon_i) = 0, \forall i$ ) ist unproblematisch, solange das Modell mit Konstante (Ordinatenabschnitt) geschätzt wird.
- Die zweite Annahme ( $Var(\epsilon_i) = \sigma^2, \forall i$ ) nennt man **Homoskedastizitäts-Annahme**.




# Modellannahmen (Forts.)

4. Die Störterme sind **nicht miteinander korreliert** (autokorreliert), so dass

$$\text{Cov}(\epsilon_t, \epsilon_{t+j}) = 0 \quad \text{für alle } j \neq 0$$

Das Problem kann bei Zeitreihendaten auftreten.



Die Störterme in der Abbildung weisen eine positive Autokorrelation auf: Auf positive (negative) Störterme folgen tendenziell positive (negative) Störterme.

# Modellannahmen (Forts.)

- Im Weiteren gehen wir davon aus, dass die Annahmen des linearen Regressionsmodells *erfüllt* sind.
- Ein wichtiger Bestandteil der Regressionsanalyse ist die sogenannte **Diagnostik**, welche sich mit der *Überprüfung* der Annahmen auseinandersetzt, insb. durch
  - Geeignete Diagramme
  - Hypothesentest-Verfahren
- Im Rahmen der vorliegenden kurzen Einführung in die Regressionsanalyse können wir nur oberflächlich darauf eingehen (siehe Übungen).
- Anzumerken ist, dass viele Verletzungen der Annahmen behoben werden können, indem
  - Variablen transformiert werden (z.B. ersetzt man  $y$  durch  $\ln(y)$ ) oder
  - zusätzliche erklärende Variablen ins Modell aufgenommen werden (multiple Regressionsanalyse).


# Stichprobenregressionsfunktion (SRF)

- Wie kann die Populationsregressionsfunktion (PRF) mit Stichproben-  
daten *geschätzt* werden?
- Das Stichproben-Pendant zur PRF ist die **Stichprobenregressions-  
funktion (SRF)**. Im Fall von Linearität kann sie lineare  
Einfachregressionsfunktion (-Gleichung) genannt und wie folgt  
geschrieben werden:

$$\hat{y}_i = b_0 + b_1 x_i$$

- wobei  $\hat{y}_i$  der Schätzer/Schätzwert von  $E(Y|x_i)$ ,  
 $b_0$  der Schätzer/Schätzwert von  $\beta_0$  und  
 $b_1$  der Schätzer/Schätzwert von  $\beta_1$  ist.
- ☞ Die Notation im Lehrmittel unterscheidet hier nicht zwischen Schätzer  
und Schätzwert.

# Lineare Einfachregressionsfunktion



- Residuum:  $e_i = y_i - \hat{y}_i$
- Lineare Einfachregression:  $e_i = y_i - \hat{y}_i = y_i - (b_0 + b_1 x_i)$

## § 2 Kleinst-Quadrate-Schätzer

- Eine gängige Methode, um die Schätzer für  $b_0$  und  $b_1$  zu finden, ist die **Methode der kleinsten Quadrate (Least Squares)**.
- Die Schätzer werden durch eine **Minimierung der Summe der quadrierten Residuen (SSE)** bezüglich  $b_0$  und  $b_1$  hergeleitet:

$$SSE = \sum_{i=1}^n e_i^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n (y_i - b_0 - b_1 x_i)^2$$

- SSE wird partiell nach  $b_0$  und  $b_1$  abgeleitet und 0 gesetzt.
  - ☞ Für interessierte Studierende: Die Herleitungen der Schätzer finden Sie in Newbold et al., Anhang zu Teil 9.

# Kleinst-Quadrate-Schätzer (Forts.)

- Lösungen des Extremalproblems

- **Steigung:**

$$b_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sum x_i^2 - n\bar{x}^2} = \frac{s_{xy}}{s_x^2} = r_{xy} \frac{s_y}{s_x}$$

- **Ordinatenabschnitt:**

$$b_0 = \bar{y} - b_1 \bar{x}$$

- $s_x^2$  ist die Stichprobenvarianz von  $X$ .
- $s_{xy}$  ist die Stichprobenkovarianz von  $X$  und  $Y$ .
- $r_{xy} = \frac{s_{xy}}{s_x s_y}$  ist der Stichprobenkorrelationskoeffizient zwischen  $X$  und  $Y$ .
- Aus der Formel für  $b_0$  folgt unmittelbar, dass die Regressionsgerade durch den Schwerpunkt der Punktwolke  $(\bar{x}, \bar{y})$  geht.


# Interpretation der Koeffizienten

- Der Ordinatenabschnitt  $b_0$  ist der geschätzte durchschnittliche Wert von  $y$ , wenn  $x = 0$  ist. In manchen Situationen gibt es allerdings keine ökonomisch sinnvolle Interpretation des Ordinatenabschnitts.
- Die Steigung  $b_1$  ist die geschätzte durchschnittliche Veränderung von  $y$  bei einem Anstieg von  $x$  um eine Einheit.

# Beispiel aus Business Intelligence Modul

## Beispiel: Immobilienbewertung

- Hedonische Methode = Vergleichswert Methode:  
Auf der Basis von Vergleichen (erklärenden Variablen) wird zu erklären versucht.



Hedonisches Modell:

$$\text{Mietpreis} = 793.843 + (36.477 \cdot \text{Zimmer}) + (9.795 \cdot \text{Fläche})$$

Mit den beiden erklärenden Variablen «Zimmer» und «Fläche» kann das Regressionsmodell als Fläche in einem 3D-Raum dargestellt werden.

Der gelbe Punkt in der Graphik entspricht einer Mietwohnung mit 4.5 Zimmern und 110m² Wohnfläche.

Die Mietpreisschätzung für diese Mietwohnung beträgt gerundet 2035.- CHF/Monat.

# Beispiel aus **Business Intelligence Modul**

## Beispiel: Immobilienbewertung (Hedonische Modelle)

### Hedonischer Preisindex: Vorgehen für die Erstellung:

1. Datenaufbereitung für die Modellierung pro Indexzeitpunkt (z.B. pro Quartal für 2000-2019)
2. Erstellen von separaten Modellen pro Indexzeitpunkt (z.B. 4 Quartale \* 20 Jahre = 80 Modelle)
3. Definition «Standardobjekte» (z.B. 4.5 Zimmer, 115m<sup>2</sup>, mittlerer Ausbaustandard, mittlere Lage)
4. Erstellung separater Preisschätzungen pro Indexzeitpunkt für die «Standardobjekte»
5. Indexierung der Preisschätzungen für das Standardobjekt (Startjahr = 100%)

Für die Gewährleistung der zeitlichen Vergleichbarkeit (ceteris paribus rule) gilt: Eine Anpassungen der Modelle/Variablen verlangt eine Neuberechnung der Index-Zeitreihe.

# Lineare Einfachregression: Beispiel


- Ein Immobilienagent möchte den Zusammenhang zwischen Verkaufspreisen von Häusern und deren Grösse untersuchen.
- Eine (sehr kleine!) Zufallsstichprobe der Grösse  $n = 10$  wird zu diesem Zweck gezogen.
  - Abhängige Variable:  $y$  = Hauspreis in \$1000
  - Unabhängige Variable:  $x$  = Fläche in Quadratfuss



|   | Beob. | $y_i$ | $x_i$ |
|---|-------|-------|-------|
| 0 | 1     | 245   | 1400  |
| 1 | 2     | 312   | 1600  |
| 2 | 3     | 279   | 1700  |
| 3 | 4     | 308   | 1875  |
| 4 | 5     | 199   | 1100  |
| 5 | 6     | 219   | 1550  |
| 6 | 7     | 405   | 2350  |
| 7 | 8     | 324   | 2450  |
| 8 | 9     | 319   | 1425  |
| 9 | 10    | 255   | 1700  |

# Graphische Darstellung des Zusammenhangs

- Eine Regressionsanalyse beginnt mit einem Streudiagramm:



- Der Zusammenhang ist approximativ linear. ✓
- Die Varianz der Störterme scheint konstant zu sein (Homoskedastizität).



# Bestimmung der Regressionsgeraden

| $y_i$        | $x_i$         | $x_i^2$           | $x_i y_i$        |
|--------------|---------------|-------------------|------------------|
| 245          | 1400          | 1'960'000         | 343'000          |
| 312          | 1600          | 2'560'000         | 499'200          |
| 279          | 1700          | 2'890'000         | 474'300          |
| 308          | 1875          | 3'515'625         | 577'500          |
| 199          | 1100          | 1'210'000         | 218'900          |
| 219          | 1550          | 2'402'500         | 339'450          |
| 405          | 2350          | 5'522'500         | 951'750          |
| 324          | 2450          | 6'002'500         | 793'800          |
| 319          | 1425          | 2'030'625         | 454'575          |
| 255          | 1700          | 2'890'000         | 433'500          |
| <b>2'865</b> | <b>17'150</b> | <b>30'983'750</b> | <b>5'085'975</b> |

$\sum_{i=1}^{10}$



# Bestimmung der Regressionsgeraden (Forts.)

$$n=10 \quad \sum y_i = 2865 \quad \sum x_i = 17150 \quad \sum x_i^2 = 30983750 \quad \sum x_i y_i = 5085975$$

$$\bar{x} = \frac{\sum x_i}{n} = \frac{17150}{10} = 1715$$

$$\bar{y} = \frac{\sum y_i}{n} = \frac{2865}{10} = 286.5$$

$$s_x^2 = \frac{\sum x_i^2 - n\bar{x}^2}{n-1} = \frac{30983750 - 10 \cdot 1715^2}{10-1} = 174611.1111$$

$$s_{xy} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{n-1} = \frac{5085975 - 10 \cdot 1715 \cdot 286.5}{10-1} = 19166.67$$

$$b_1 = \frac{s_{xy}}{s_x^2} = \frac{19166.67}{174611.1111} = 0.109768$$

$$b_0 = \bar{y} - b_1 \bar{x} = 286.5 - 0.109768 \cdot 1715 = 98.25$$

$$\hat{y}_i = b_0 + b_1 x_i = 98.25 + 0.110 x_i$$



# Bestimmung der Regressionsgeraden mit Computer / TR

- Die Koeffizienten  $b_0$  und  $b_1$  und andere Regressionsresultate in diesem Teil werden meist mit Computer bzw. Taschenrechner ermittelt.
- Berechnungen von Hand sind ermüdend und werden nur in sehr kleinen Datensätzen zur Illustration vorgenommen.
- Die nötigen statistischen Routinen sind in Statistik-Softwarepaketen implementiert (z.B. Excel oder Python) und eingeschränkt auch in vielen Taschenrechnern (z.B. Casio fx-991ES)

# Bestimmung der Regressionsgeraden

## OLS Regression Results

```

=====
Dep. Variable:          y_i      R-squared:          0.581
Model:                OLS      Adj. R-squared:       0.528
Method:              Least Squares  F-statistic:       11.08
Date:                Thu, 17 Oct 2019  Prob (F-statistic):    0.0104
Time:                21:55:23    Log-Likelihood:     -50.290
No. Observations:      10      AIC:              104.6
Df Residuals:          8      BIC:              105.2
Df Model:              1
Covariance Type:      nonrobust
=====

```

```

=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
const          98.2483      58.033      1.693      0.129     -35.577     232.074
x_i             0.1098       0.033      3.329      0.010       0.034       0.186
=====

```

```


=====
Omnibus:          1.066      Durbin-Watson:          3.222
Prob(Omnibus):    0.587      Jarque-Bera (JB):        0.779
Skew:             0.399      Prob(JB):               0.677
Kurtosis:         1.890      Cond. No.               7.82e+03
=====

```



# Bestimmung der Regressionsgeraden

Dazu gehört auch ein Scatterplot mit einer entsprechenden Regressionsgeraden:



# Bestimmung der Regressionsgeraden

- Die Regressionsgleichung lautet:


$$\hat{y}_i = 98.248 + 0.110x_i$$

|       | coef    | std err | t     | P> t  | [0.025  | 0.975]  |
|-------|---------|---------|-------|-------|---------|---------|
| const | 98.2483 | 58.033  | 1.693 | 0.129 | -35.577 | 232.074 |
| x_i   | 0.1098  | 0.033   | 3.329 | 0.010 | 0.034   | 0.186   |



# Graphische Darstellung

- Hauspreismodell: Streuungsdiagramm mit Regressionsgerade



Ordinaten-  
abschnitt  
 $b_0 = 98.248$

$X = 0$

Steigung  
 $b_1 = 0.110$



# Interpretation der Koeffizienten

- $\hat{y}_i = 98.248 + 0.110 x_i$

- $b_0$  ist der geschätzte durchschnittliche Wert von  $y$ , falls  $x$  den Wert 0 annimmt und  $x = 0$  möglich bzw. sinnvoll ist, was im vorliegenden Fall nicht zutrifft.

- $\hat{y}_i = 98.248 + 0.110 x_i$


- $b_1$  misst die geschätzte durchschnittliche Veränderung in  $y$ , falls  $x$  um eine Einheit zunimmt. Im Beispiel bedeutet  $b_1 = 0.110$ , dass der durchschnittliche Hauspreis für jeden zusätzlichen Quadratfuss an Grundfläche um geschätzte  $0.110 \cdot \$1000 = \$110$  zunimmt.



# Prognose-Punktschätzung (Beispiel)

- Wie hoch ist der geschätzte Preis eines Hauses mit einer Grundfläche von 1500 ft<sup>2</sup>?
- Lösung:

$$\hat{y}_i = 98.248 + 0.110 \cdot 1500 = 263.20 \text{ (in \$1000)}$$



## Voraussetzung:

- Die Modellannahmen gelten auch für den Zeitpunkt/Ort, wo die Prognose Verwendung findet.



## § 3 Zerlegung der Gesamtstreuung

- Ziele:
  - Mass für die Güte des linearen Zusammenhangs.
  - Inferenzschlüsse bezüglich der Regressionsparameter
- Die totale Streuung von  $y$  kann in zwei Teile zerlegt werden:

$$SST = SSR + SSE$$

Totale  
Quadratsumme  
(Total Sum of Squares)

Quadratsumme der  
Regression  
(Regression Sum of Squares)

Quadratsumme der  
Fehler  
(Error Sum of Squares)

$$SST = \sum (y_i - \bar{y})^2$$

$$SSR = \sum (\hat{y}_i - \bar{y})^2$$


$$SSE = \sum (y_i - \hat{y}_i)^2$$

wobei:  $y_i$  = Beobachteter Wert der abhängigen Variable  
 $\bar{y}$  = Mittelwert der zu erklärenden Variable  
 $\hat{y}_i$  = Schätzwert von  $y$  für gegebenen  $x_i$ -Wert

# Zerlegung der Gesamtstreuung (Forts.)

- $SST$  = Totale Quadratsumme (total sum of squares)
    - Misst die Streuung der  $y$ -Werte um deren Mittelwert  $\bar{y}$ .
  - $SSR$  = Quadratsumme der Regression (regression sum of squares)
    - Erklärte Variation von  $y$ , welche auf die lineare Beziehung mit  $x$  zurückzuführen ist.
  - $SSE$  = Quadratsumme der Fehler (error sum of squares)
    - Variation von  $y$ , welche *nicht* auf die lineare Beziehung mit  $x$  zurückzuführen ist.
- ☞ Hinweis: In der Literatur haben  $SSR$  und  $SSE$  manchmal gerade die umgekehrte Bedeutung ( $SSR$  = residual sum of squares,  $SSE$  = explained sum of squares).

# Zerlegung der Gesamtstreuung (Forts.)



# Zerlegung der Gesamtstreuung im Beispiel der Hauspreise

- Regressionsgerade:  $\hat{y}_i = 98.2483 + 0.109768x_i$ ,  $\bar{y} = 286.5$

| $y_i$       | $x_i$         | $\hat{y}_i$ | $(y_i - \bar{y})^2$ | $(\hat{y}_i - \bar{y})^2$ | $(y_i - \hat{y}_i)^2 = e_i^2$ |
|-------------|---------------|-------------|---------------------|---------------------------|-------------------------------|
| 245         | 1400          | 251.92      | 1722.25             | 1195.56                   | 47.93                         |
| 312         | 1600          | 273.88      | 650.25              | 159.35                    | 1453.39                       |
| 279         | 1700          | 284.85      | 56.25               | 2.71                      | 34.26                         |
| 308         | 1875          | 304.06      | 462.25              | 308.45                    | 15.50                         |
| 199         | 1100          | 218.99      | 7656.25             | 4557.22                   | 399.71                        |
| 219         | 1550          | 268.39      | 4556.25             | 328.03                    | 2439.21                       |
| 405         | 2350          | 356.20      | 14042.25            | 4858.44                   | 2381.19                       |
| 324         | 2450          | 367.18      | 1406.25             | 6509.15                   | 1864.45                       |
| 319         | 1425          | 254.67      | 1056.25             | 1013.32                   | 4138.69                       |
| 255         | 1700          | 284.85      | 992.25              | 2.71                      | 891.23                        |
| <b>2865</b> | <b>17,150</b> | <b>2865</b> | <b>32600.50</b>     | <b>18934.93</b>           | <b>13665.57</b>               |

$\sum_{i=1}^{10}$



Die Zerlegung gilt nur für die Summen, nicht für die einzelnen Zeilen!

$$\text{SST} = \text{SSR} + \text{SSE}$$

# Bestimmtheitsmass, $R^2$

- Das **Bestimmtheitsmass** («**R-Quadrat**») ist der *Anteil* der totalen Variation (Quadrat-summe) der abhängigen Variable, welche durch die Regression erklärt wird.


$$R^2 = \frac{SSR}{SST} = \frac{\sum(\hat{y}_i - \bar{y})^2}{\sum(y_i - \bar{y})^2} = 1 - \frac{SSE}{SST}$$

- Das Bestimmtheitsmass  $R^2$  entspricht bei der linearen Einfachregression dem Korrelationskoeffizienten im Quadrat.

$$R^2 = r_{xy}^2$$

- Es gilt:  $0 \leq R^2 \leq 1$


# $R^2$ : Graphische Veranschaulichung




$$R^2 = 1$$

## Perfekter linearer Zusammenhang zwischen $x$ und $y$ :

- Alle Punkte liegen auf einer Geraden mit Steigung  $b_1 \neq 0$ .
- 100% der Streuung von  $y$  ist durch die Streuung von  $x$  (durch eine *lineare* Funktion) erklärt.




## $R^2$ : Graphische Veranschaulichung (Forts.)




$$0 < R^2 < 1$$

**Schwächerer linearer Zusammenhang zwischen  $x$  und  $y$ :**

Die Streuung von  $y$  kann nur teilweise durch die Variation von  $x$  erklärt werden.




## $R^2$ : Graphische Veranschaulichung (Forts.)



$$R^2 \approx 0$$

**Kein linearer Zusammenhang zwischen  $x$  und  $y$ :**

- $y$  hängt nicht von  $x$  ab. (Nichts von der Gesamtstreuung von  $y$  um  $\hat{y}$  kann durch die Variation von  $x$  erklärt werden.)
- Die  $y$ -Werte hängen nicht linear von den  $x$ -Werten ab.  
(Aber es gibt einen *quadratischen* Zusammenhang in der zweiten Abb.)



# Interpretation des Programm-Outputs (I)

58.1% der totalen Streuung der Hauspreise kann durch den linearen Zusammenhang mit der Fläche der Häuser erklärt werden.

| OLS Regression Results |                  |                     |          |       |         |         |
|------------------------|------------------|---------------------|----------|-------|---------|---------|
| Dep. Variable:         | y_i              | R-squared:          | 0.581    |       |         |         |
| Model:                 | OLS              | Adj. R-squared:     | 0.528    |       |         |         |
| Method:                | Least Squares    | F-statistic:        | 11.08    |       |         |         |
| Date:                  | Thu, 17 Oct 2019 | Prob (F-statistic): | 0.0104   |       |         |         |
| Time:                  | 21:55:23         | Log-Likelihood:     | -50.290  |       |         |         |
| No. Observations:      | 10               | AIC:                | 104.6    |       |         |         |
| Df Residuals:          | 8                | BIC:                | 105.2    |       |         |         |
| Df Model:              | 1                |                     |          |       |         |         |
| Covariance Type:       | nonrobust        |                     |          |       |         |         |
|                        | coef             | std err             | t        | P> t  | [0.025  | 0.975]  |
| const                  | 98.2483          | 58.033              | 1.693    | 0.129 | -35.577 | 232.074 |
| x_i                    | 0.1098           | 0.033               | 3.329    | 0.010 | 0.034   | 0.186   |
| Omnibus:               | 1.066            | Durbin-Watson:      | 3.222    |       |         |         |
| Prob(Omnibus):         | 0.587            | Jarque-Bera (JB):   | 0.779    |       |         |         |
| Skew:                  | 0.399            | Prob(JB):           | 0.677    |       |         |         |
| Kurtosis:              | 1.890            | Cond. No.           | 7.82e+03 |       |         |         |

$$R^2 = \frac{SSR}{SST} = \frac{18934.935}{32600.500} = 0.581$$



# Standardfehler der Schätzung

- Ein Schätzer für die Varianz der Störterme ist

$$\hat{\sigma}^2 = s_e^2 = \frac{\sum_{i=1}^n (e_i^2 - \overline{e^2})^2}{n-2} = \frac{\sum_{i=1}^n e_i^2}{n-2} = \frac{SSE}{n-2}$$

- Man teilt durch die Anzahl Freiheitsgrade  $n-2$  (nicht  $n-1$ ), da bei der Einfachregression zwei Freiheitsgrade durch die Schätzung der Parameter  $b_0$  und  $b_1$  verloren gehen.
- $s_e = \sqrt{s_e^2}$  nennt man den **Standardfehler der Schätzung/Regression**

# Interpretation des Programm-Outputs (II)

$$s_e = \sqrt{\frac{SSE}{n-2}} = \sqrt{\frac{13665.57}{10-2}} = 41.330$$

```
from sklearn.linear_model import LinearRegression
lr = LinearRegression(fit_intercept=True)
lr.fit(x, y)
y_pred = lr.predict(x)
SSE = mean_squared_error(y, y_pred)*len(x)
MSE = np.sqrt(SSE/(len(x)-2))
print("")
print("Number of Observations: %.0f" % len(y))
print("")
print("SSE: %.2f" % SSE)
print("")
print("Root MSE: %.2f" % MSE)
```

Number of Observations: 10

SSE: 13665.57


Root MSE: 41.33

Überprüfen Sie das Ergebnis mit den Statistiken auf S. 31




# Standardfehler: Graphische Darstellung

- $s_e$  ist ein Mass für die Streuung der beobachteten  $y$ -Werte um die Regressionsgerade.



$s_e$  klein



$s_e$  gross

- Die Grösse von  $s_e$  muss in Relation zur Grösse der  $y$ -Werte gesetzt werden bei einer Beurteilung (siehe  $R^2$ ).
- Z.B.,  $s_e = \$41'333$  ist «mittelgross» relativ zu den Hauspreisen im Bereich von  $\$200'000$  bis  $\$300'000$ .



## § 4 Inferenz: Hypothesentests und Konfidenzintervalle

- Die Varianz der Koeffizienten  $b_0$  und  $b_1$  wird mit den folgenden Formeln geschätzt. (Interessierte Studierende finden die Herleitungen der Formeln im Lehrmittel.)

$$\begin{aligned}\text{Var}(b_1) &= s_{b_1}^2 = \frac{s_e^2}{\sum (x_i - \bar{X})^2} = \frac{s_e^2}{(n-1)s_x^2} \\ \text{Var}(b_0) &= s_{b_0}^2 = \left( \frac{1}{n} + \frac{\bar{X}^2}{(n-1)s_x^2} \right) s_e^2\end{aligned}$$

wobei:

$s_{b_1}, s_{b_0}$  = geschätzte Standardfehler der Regressions-Koeffizienten

$$s_e = \sqrt{\frac{SSE}{n-2}} = \text{Standardfehler der Regression}$$

# Interpretation des Programm-Outputs (III)

## OLS Regression Results

```
=====
Dep. Variable:          y_i      R-squared:          0.581
Model:                  OLS      Adj. R-squared:       0.528
Method:                 Least Squares      F-statistic:    11.08
Date:                  Thu, 17 Oct 2019    Prob (F-statistic): 0.0104
Time:                  21:55:23      Log-Likelihood:    -50.290
No. Observations:      10      AIC:                104.6
Df Residuals:          8      BIC:                105.2
Df Model:               1
Covariance Type:       nonrobust
=====
```

```
=====
              coef      std err          t      P>|t|      [0.025      0.975]
-----
const          98.2483      58.033          1.693      0.129     -35.577     232.074
x_i             0.1098       0.033          3.329      0.010       0.034       0.186
=====
```

```
=====
Omnibus:          1.066      Durbin-Watson:          3.222
Prob(Omnibus):    0.587      Jarque-Bera (JB):          0.779
Skew:             0.399      Prob(JB):                0.677
Kurtosis:         1.890      Cond. No.                7.82e+03
=====
```

$$s_{b_0} = 58.033$$



$$s_{b_1} = 0.033$$



# Standardfehler der Steigung

- $s_{b_1}$  ist ein Mass für die Streuung der Steigung über unterschiedliche mögliche Stichproben.

Variation von  $b_1$  von  
Stichprobe zu Stichprobe



# Standardfehler der Steigung (Forts.)

- Was beeinflusst den Standardfehler von  $b_1$ ?

$$s_{b_1}^2 = \frac{s_e^2}{\sum (x_i - \bar{x})^2} = \frac{s_e^2}{(n-1)s_x^2}$$

- Je kleiner der Standardfehler der Regression ( $s_e$ ), desto kleiner ist der Standardfehler der Steigung.
- Je höher die Streuung der  $x$ -Werte ( $s_x$ ), desto kleiner ist der Standardfehler der Steigung.
- Je grösser die Stichprobe ( $n$ ), desto kleiner ist der Standardfehler der Steigung.

# Inferenz bezüglich der Koeffizienten

Inferenz bezüglich der Populations-Regressionsparameter  $\beta_0$  und  $\beta_1$ .

- **Voraussetzung:**
  - Die Regressionsannahmen sind erfüllt.
  - Die Störterme,  $\varepsilon_i$ , sind normalverteilt oder die Stichprobe ist gross genug (für den zentralen Grenzwertsatz).
- Sind die Voraussetzungen erfüllt, dann ist die Zufallsvariable

$$T = \frac{b_1 - \beta_1}{s_{b_1}}$$

(approximativ) Student-verteilt mit  $n - 2$  Freiheitsgraden.

# $t$ -Test für die Populationssteigung $\beta_1$

- Gibt es eine lineare Beziehung zwischen  $y$  und  $x$ ?
- Null- und Alternativhypothese:
  - $H_0: \beta_1 = 0$  (keine lineare Beziehung)
  - $H_1: \beta_1 \neq 0$  (eine Beziehung – aber nicht unbedingt eine lineare – besteht zwischen  $y$  und  $x$ )
- Teststatistik:

$$t = \frac{b_1 - \beta_1^*}{s_{b_1}}$$

$$FG = n - 2$$

wobei:

$b_1$  = Stichprobenregressionssteigung

$\beta_1^*$  = Steigung unter  $H_0$ , hier 0

$s_{b_1}$  = Standardfehler der Stichprobensteigung

# $t$ -Test für die Populationssteigung $\beta_1$ (Forts.)

|   | Beob. | $y_i$ | $x_i$ |
|---|-------|-------|-------|
| 0 | 1     | 245   | 1400  |
| 1 | 2     | 312   | 1600  |
| 2 | 3     | 279   | 1700  |
| 3 | 4     | 308   | 1875  |
| 4 | 5     | 199   | 1100  |
| 5 | 6     | 219   | 1550  |
| 6 | 7     | 405   | 2350  |
| 7 | 8     | 324   | 2450  |
| 8 | 9     | 319   | 1425  |
| 9 | 10    | 255   | 1700  |

## Geschätzte Regressionsgleichung:

$$\hat{y}_i = 98.25 + 0.110x_i$$


- Die geschätzte Steigung ist 0.110.
- Gibt es einen statistisch signifikanten Zusammenhang zwischen Hauspreis und Hausgrösse?
- Da die Stichprobe sehr klein ist, müssen wir von normalverteilten Störtermen ausgehen. (Diese Annahme könnte mittels Python *getestet* werden.)



# $t$ -Test für die Populationssteigung $\beta_1$ (Forts.)

Output:

|       | coef    | std err | t     | P> t  | [0.025  | 0.975]  |
|-------|---------|---------|-------|-------|---------|---------|
| const | 98.2483 | 58.033  | 1.693 | 0.129 | -35.577 | 232.074 |
| x_i   | 0.1098  | 0.033   | 3.329 | 0.010 | 0.034   | 0.186   |



$$t = \frac{b_1 - \beta_1}{s_{b_1}} = \frac{0.110 - 0}{0.033} = 3.329$$



# $t$ -Test für die Populationssteigung $\beta_1$ (Forts.)


$$H_0: \beta_1 = 0$$

$$H_1: \beta_1 \neq 0$$

$$FG = 10 - 2 = 8$$

$$t_{8, .025} = 2.3060$$

Teststatistik:  **$t = 3.329$**



## Fazit:

Es gibt genügend Evidenz, dass es einen Zusammenhang zwischen Hauspreisen und Hausgrößen gibt.

## Hinweis:

Man hätte auch einseitig testen können.

Entscheidung:  
 **$H_0$  verwerfen**



# $t$ -Test für die Populationssteigung $\beta_1$ (Forts.)

Schneller und einfacher ist es, den Test mittels  $p$ -Wert durchzuführen, der von Statistikprogrammen ausgegeben wird.

|       | coef    | std err | t     | P> t  | [0.025  | 0.975]  |
|-------|---------|---------|-------|-------|---------|---------|
| const | 98.2483 | 58.033  | 1.693 | 0.129 | -35.577 | 232.074 |
| x_i   | 0.1098  | 0.033   | 3.329 | 0.010 | 0.034   | 0.186   |

Beim zweiseitigen Test ist der  $p$ -Wert gleich:  
 $P(t > 3.329) + P(t < -3.329) = \mathbf{0.010}$  (für 8 FG)

## Entscheidung:

$p$ -Wert  $< \alpha$ , somit wird  $H_0$  verworfen.



Das Ausmass der Signifikanz kann unterschieden werden:

- $p < 1\%$ : hochsignifikant (\*\*\*)
- $1\% \leq p < 5\%$ : signifikant (\*\*)
- $5\% \leq p < 10\%$ : schwach signifikant (\*)
- $p \geq 10\%$ : nicht signifikant

# Konfidenzintervalle für $\beta_0$ und $\beta_1$

- $(1 - \alpha)$ -Konfidenzintervall für  $\beta_k$ :

$$b_k \pm t_{n-2, \alpha/2} S_{b_k} \quad k = 0, 1 \quad (FG = n - 2)$$

- Interpretation des Outputs für das Hauspreisbeispiel:



|       | coef    | std err | t     | P> t  | [0.025  | 0.975]  |
|-------|---------|---------|-------|-------|---------|---------|
| const | 98.2483 | 58.033  | 1.693 | 0.129 | -35.577 | 232.074 |
| x_i   | 0.1098  | 0.033   | 3.329 | 0.010 | 0.034   | 0.186   |

# Konfidenzintervall für die Steigung: Interpretation

|       | coef    | std err | t     | P> t  | [0.025  | 0.975]  |
|-------|---------|---------|-------|-------|---------|---------|
| const | 98.2483 | 58.033  | 1.693 | 0.129 | -35.577 | 232.074 |
| x_i   | 0.1098  | 0.033   | 3.329 | 0.010 | 0.034   | 0.186   |



Mit „95%-Sicherheit“ steigt der Hauspreis zwischen  $0.034(\$1000)=\$34$  und  $0.186(\$1000)=\$186$  pro zusätzlicher Quadratfuss Hausfläche

**Das 95%-Konfidenzintervall beinhaltet nicht 0.**

**Folgerung:** Es gibt einen signifikanten (linearen) Zusammenhang zwischen Hauspreis und Hausgrösse (Signifikanzniveau=5%)